Московский государственный университет имени М.В. Ломоносова

факультет вычислительной математики и кибернетики

кафедра информационной безопасности

Магистерская диссертация

Магистерская программа «Название магистерской программы»

Исследование и разработка алгоритма построения рекомендаций с использованием контекстной и сессионной информации пользователя

Выполнил:
студент группы XXX
Бадекин Илья Иванович

Научный руководитель:
Ассистент
Ильюшин Е.А.

Рецензент:
к.ф.-м.н., доцент
Фамилия И.О.

Москва, 2026

Оглавление

Введение 4

1 Обзор литературы 8

1.1 Формальная постановка задачи последовательной и сессионной рекомендации 8

1.1.1 Основные определения и нотация 8

1.1.2 Функции потерь 9

1.1.3 Метрики качества 9

1.2 Сессионные рекомендательные системы: от RNN к Transformer и далее 10

1.2.1 Основополагающие архитектуры 2015–2019 10

1.2.2 Калибровка и эффективные альтернативы 2022–2025 . 11

1.2.3 Session-aware трансформеры: иерархическое кодирование сессий 11

1.2.4 Самообучение и контрастивные методы для session-aware рекомендаций 13

1.3 Учёт временной информации: от интервалов до ротационных эмбеддингов 14

1.3.1 Временные интервалы в механизме внимания 14

1.3.2 Периодические кодирования времени 15

1.3.3 Ротационные позиционные эмбеддинги в рекомендациях 15

1.3.4 Устаревание эмбеддингов и временной спад 15

1.4 Гибридные эмбеддинги и проблема dimensional collapse 16

1.4.1 Deep & Cross Network для формирования представлений 16

1.4.2 Dimensional collapse в рекомендательных моделях . . . 16

1.4.3 Hash-based эмбеддинги для больших каталогов 16

1.4.4 Иерархические и композитные представления товаров . 17

1.5 Контекстуальная информация: запросы, типы действий, сессионные токены . . . 18
1.5.1 Учёт поисковых запросов в последовательных рекомендациях . . . 18
1.5.2 Разделение типов действий (multi-behavior recommendation) 19
1.5.3 Негативная выборка из просмотренных товаров . . . 19
1.5.4 Сессионные разделительные токены . . . 19
1.5.5 Моделирование эволюции интересов пользователя . . . 20
1.5.6 Disentanglement интентов: разделение устойчивых и волатильных компонент . . . 21
1.5.7 Обогащение контекста через внешние структурированные знания . . . 22
1.6 Графовые подходы к сессионным рекомендациям . . . 23
1.6.1 От SR-GNN к глобальному контексту . . . 23
1.6.2 Графовая коллаборативная фильтрация . . . 24
1.6.3 Гетерогенные графы . . . 24
1.7 Архитектурные улучшения для промышленных систем . . . 24
1.7.1 Mixture of Experts в рекомендациях . . . 24
1.7.2 TorchRec и jagged tensors . . . 25
1.7.3 Knowledge distillation и LoRA . . . 25
1.8 Наборы данных для оценки . . . 26
1.8.1 Amazon Reviews . . . 26
1.8.2 MovieLens-1M . . . 26
1.8.3 Tmall (IJCAI-15) . . . 27
1.8.4 Coveo SIGIR eCommerce Dataset . . . 27
1.8.5 Сравнительная характеристика датасетов . . . 27
1.9 Метрики оценки качества рекомендаций . . . 28
1.9.1 Основные метрики ранжирования . . . 28
1.9.2 Дополнительные метрики для session-aware анализа . . . 29
1.9.3 Протокол оценки . . . 29
1.10 Функции потерь и стратегии отбора негативных примеров . . . 30
1.10.1 Корень проблемы: конфликт лёгких и ложных негативов 30
1.10.2 Отбор на стороне сэмплера . . . 31
1.10.3 Объективы с внутренней конкуренцией между негативами 31

1.10.4 Калибровка BCE и согласование с top-K 32
1.10.5 Надёжность негативов и коррекция ложных срабатываний 33
1.10.6 Позиционирование предлагаемого подхода 33
1.11 Выводы по главе 34

2 Описание предлагаемого метода 38
2.1 Постановка задачи 38
2.2 Предлагаемый подход 38
2.2.1 Общая архитектура 39
2.2.2 Иерархические композитные представления товаров . . 39
2.2.3 Иерархический временные эмбеддинги 41
2.2.4 Функция потерь с асимметричным Коши-взвешиванием негативов 44
2.3 Выводы по главе 46

3 Результаты экспериментов 47
3.1 Описание эксперимента 47
3.2 Анализ результатов 47
3.3 Выводы по главе 47

4 Обсуждение и сравнительный анализ 48
4.1 Сравнение с существующими решениями 48
4.2 Ограничения предложенного подхода 48
4.3 Направления дальнейших исследований 48
4.4 Выводы по главе 48

Заключение 49

Список литературы 50

A Дополнительные материалы 61

Введение

Актуальность темы исследования. Задача предсказания следующего взаимодействия пользователя с товарным каталогом — одна из центральных в области машинного обучения для информационного поиска и рекомендательных систем. Её фундаментальная сложность определяется дуальностью природы предпочтений: пользователь одновременно обладает *устойчивыми долгосрочными интересами* (жанровые предпочтения, ценовой диапазон, брендовая лояльность) и *изменчивыми краткосрочными намерениями* (целевая покупка, ситуативный интерес, сезонная потребность). Классические подходы коллаборативной фильтрации и матричной факторизации [7] моделируют только первую составляющую; ранние рекуррентные модели [72] работают преимущественно со второй.

Переход к трансформерным архитектурам [6; 34] позволил значительно улучшить моделирование последовательных зависимостей, однако выявил новую проблему: *отсутствие структурной разметки времени*. Реальная история взаимодействий пользователя не является однородной последовательностью — она организована в *сессии*: компактные временны'е кластеры активности, разделённые значимыми паузами. Временные разрывы между сессиями несут самостоятельную семантику: они кодируют смену контекста, завершение цикла потребности, начало нового намерения. Игнорирование этой структуры приводит к систематическому смешению разнородных сигналов — явлению, которое в данной работе обозначается как *проблема семантической однородности последовательности*.

Параллельно с развитием последовательных моделей оформилось направление session-aware рекомендаций [60] — персонализированного рекомендования для авторизованных пользователей с явным учётом сессионной структуры их истории. Несмотря на теоретическую ясность постановки, эмпирическое исследование данного направления остаётся фрагментарным: существующие модели рассматривают отдельные аспекты задачи — иерархию сессий [1], временны'е интервалы [42], атрибуты товаров [62], поисковые запросы [61] — но не исследуют их *совместное* влияние на качество рекомендаций в едином контролируемом эксперименте.

Мотивация исследования. Системный анализ литературы (см. раз-

дел 1.2) позволяет сформулировать *три нерешённые научные проблемы*, определяющие мотивацию данной работы.

Проблема 1: интеграция разноуровневых временны'х сигналов. Механизм самовнимания в трансформерах работает с позиционными индексами, игнорируя абсолютные временны'е метки и семантику временны'х разрывов. Существующие решения — временны'е интервалы в матрице внимания [42] и сессионные токены [69] — решают проблему независимо. Остаётся открытым вопрос об оптимальной интеграции непрерывного времени, дискретных сессионных границ и порядкового контекста в единое позиционное представление.

Проблема 2: неполнота поведенческого сигнала. В e-commerce пользователь производит качественно различные действия — просмотр, добавление в корзину, покупку — которые несут различную информацию о его намерении. Большинство моделей работает только с одним типом взаимодействий (как правило, кликами), теряя богатый сигнал о силе намерения. При этом явный текст поисковых запросов, сопровождающих сессию, вовсе не учитывается в архитектурах, ориентированных исключительно на идентификаторы товаров [6; 34]. Также вопрос оптимального обуславливания сессий контекстуальной информацией остается открытым.

Проблема 3: отсутствие унифицированного бенчмарка. Сравнение существующих session-aware моделей затруднено различием в используемых наборах данных, протоколах оценки и наборах базовых решений. Работы по иерархическим моделям [1; 60] используют одни датасеты; работы по временны'м трансформерам [5; 42] — другие. Отсутствует систематическое сравнение, контролирующее все переменные и охватывающее все четыре класса контекстных сигналов.

Научная новизна. Научная новизна диссертационного исследования состоит в следующем.

1. **Постановка задачи мультиконтекстного session-aware рекомендования.** Впервые формализована задача совместного моделирования четырёх типов контекстных сигналов — сессионных границ, временных интервалов, типов поведенческих действий и контекстуальной информации — в рамках единой вероятностной модели предсказания следующего взаимодействия авторизованного пользователя.

2. **Введено балансирование вклада взависимостои от длины и по типу событий.** ...

3. **Схема позиционного кодирования для сессионно-структурированных последовательностей.** Предложен метод совместного кодирования глобальной позиции, локальной позиции внутри сессии, индекса сессии и непрерывного временного интервала между сессиями — как расширение ротационных позиционных эмбеддингов [65] применительно к иерархическим последовательностям и создания временного базиса набора базисных функций с обучаемыми параметрами.

4. **Сравнительное исследование классов контекстных сигналов.** Проведено систематическое абляционное исследование, позволяющее количественно оценить вклад каждого из четырёх классов контекстных сигналов в качество рекомендаций на четырёх разнородных датасетах (Amazon, MovieLens-1M, Tmall, Coveo) в единых условиях эксперимента.

Целью данной работы является разработка и исследование алгоритма рекомендательной системы, учитывающего контекстную и сессионную информацию о действиях пользователя для повышения качества персонализированных рекомендаций.

Для достижения поставленной цели в работе решаются следующие задачи:

1. провести систематический анализ научной литературы в области рекомендательных систем и предложить классификацию существующих методов, использующих контекстную и сессионную информацию;

2. разработать методологию экспериментальной оценки и подготовить наборы данных для количественного анализа вклада предлагаемых улучшений;

3. разработать и реализовать модификацию существующего алгоритма рекомендаций, позволяющую более эффективно использовать контекстную и сессионную информацию о поведении пользователя;

4. провести абляционное исследование предложенного алгоритма с целью оценки вклада отдельных компонент модели в итоговое качество рекомендаций.

Научная новизна работы заключается в . . .
Практическая значимость полученных результатов состоит в . . .
Основные результаты работы докладывались на . . .
По теме диссертации опубликовано . . .
Диссертация состоит из . . .
В первой главе рассматривается . . .
Во второй главе описывается . . .
В третьей главе приводятся . . .
В четвёртой главе проводится . . .

1. Обзор литературы

Современные рекомендательные системы для маркетплейсов эволюционировали от матричной факторизации к глубоким последовательным моделям, графовым нейросетям и генеративным архитектурам триллионного масштаба. Ключевой тренд 2020–2025 годов — переход от чисто позиционного моделирования последовательностей к мультимодальному учёту времени, типов действий, поисковых запросов и структуры сессий. В настоящей главе систематизированы основные направления исследований, формирующие теоретический фундамент для задачи построения рекомендаций с использованием контекстной и сессионной информации пользователя.

1.1. Формальная постановка задачи последовательной и сессионной рекомендации

1.1.1. Основные определения и нотация

Пусть $\mathcal{U} = \{u_1, u_2, \ldots, u_N\}$ — множество пользователей, $\mathcal{I} = \{i_1, i_2, \ldots, i_M\}$ — множество товаров (каталог маркетплейса). Для каждого пользователя $u \in \mathcal{U}$ определена хронологически упорядоченная последовательность взаимодействий $\mathcal{S}^u = (S_1^u, S_2^u, \ldots, S_{|\mathcal{S}^u|}^u)$, где $S_t^u \in \mathcal{I}$ — товар, с которым пользователь взаимодействовал в момент времени t. В сессионной постановке анонимная сессия определяется как упорядоченный по времени список $s = [v_{s,1}, v_{s,2}, \ldots, v_{s,n}]$, где $v_{s,i} \in \mathcal{V}$ — товар, на который пользователь кликнул в рамках сессии s [71].

Задача предсказания следующего товара (next-item prediction) формулируется следующим образом: по данной последовательности $(S_1^u, \ldots, S_t^u)$ необходимо определить S_{t+1}^u. Модель вычисляет релевантности каждого товара i как

$$r_{i,t} = \mathbf{F}_t^{(b)} \cdot \mathbf{M}_i^\top, \tag{1.1}$$

где $\mathbf{F}_t^{(b)} \in \mathbb{R}^d$ — выход b-го блока модели на позиции t, $\mathbf{M}_i \in \mathbb{R}^d$ — эмбеддинг товара i. В сессионной постановке выходной вектор вероятностей определяется как

$$\hat{\mathbf{y}} = \mathrm{softmax}(\mathbf{s}_h^\top \mathbf{V}), \tag{1.2}$$

где $\mathbf{s}_h$ — представление сессии, $\mathbf{V}$ — матрица эмбеддингов всех товаров.

1.1.2. Функции потерь

В литературе используются четыре основных класса функций потерь.

Binary Cross-Entropy (BCE), применяемая в SASRec [34], вычисляется попарно с одним негативным примером на каждую позицию:

$$\mathcal{L}_{\text{BCE}} = -\sum_{u \in \mathcal{U}} \sum_{t=1}^{|\mathcal{S}^u|} \left[\log \sigma(r_{o_t,t}) + \log(1 - \sigma(r_{o'_t,t})) \right]. \tag{1.3}$$

BPR-loss (Bayesian Personalized Ranking) [7] оптимизирует попарное ранжирование:

$$\mathcal{L}_{\text{BPR}} = -\sum_{(u,i,j) \in D_S} \ln \sigma(\hat{x}_{ui} - \hat{x}_{uj}) + \lambda_\Theta \|\Theta\|^2, \tag{1.4}$$

где $D_S = \{(u, i, j) \mid i \in \mathcal{I}_u^+ \wedge j \in \mathcal{I} \setminus \mathcal{I}_u^+\}$.

Cross-Entropy по полному каталогу (SR-GNN, BERT4Rec) определяется как $\mathcal{L}_{\text{CE}} = -\log \hat{y}_{v^*}$, а при вычислительной неподъёмности полного softmax применяется **Sampled Softmax**, ограничивающий знаменатель подмножеством отобранных негативов. Отдельно развивается направление **контрастивных потерь** (InfoNCE), впервые применённых к последовательным рекомендациям в CL4SRec [11].

1.1.3. Метрики качества

Стандартные метрики оценки включают **HitRate@K** (доля случаев, когда целевой товар попал в top-K), **MRR@K** (Mean Reciprocal Rank — среднее обратного ранга целевого товара), **NDCG@K** (Normalized Discounted Cumulative Gain) и **Recall@K**. Важно отметить, что Krichene и Rendle [38] показали, что метрики, вычисленные на подвыборке негативов, могут давать несогласованные рейтинги моделей; в текущей практике предпочтительна оценка по полному каталогу.

1.2. Сессионные рекомендательные системы: от RNN к Transformer и далее

1.2.1. Основополагающие архитектуры 2015–2019

Первопроходцем в применении глубокого обучения к сессионным рекомендациям стала модель **GRU4Rec** [72]. Авторы предложили использовать Gated Recurrent Unit для обработки последовательности кликов в анонимной сессии, введя session-parallel mini-batches для эффективного обучения и специализированные ранжирующие функции потерь (BPR и TOP1). Формула обновления скрытого состояния: $h_t = \mathrm{GRU}(x_t, h_{t-1})$, где x_t — эмбеддинг товара на шаге t. Улучшенная версия с Top-k gains [30] дала прирост 35% относительно оригинала.

NARM [50] расширила подход RNN гибридным энкодером с механизмом внимания. Модель использует два параллельных GRU: глобальный для захвата последовательного поведения и локальный с attention для определения основной цели пользователя в сессии. Представление сессии формируется как конкатенация $c_t = [c_g; c_l]$, где $c_g = h_T^g$ — финальное скрытое состояние глобального энкодера, а $c_l = \sum \alpha_t h_t^l$ — взвешенная сумма состояний локального.

STAMP [75] отказалась от рекуррентности, заменив её на простой attention-механизм с MLP. Модель захватывает общие интересы (средний пулинг эмбеддингов сессии) и текущий интерес (эмбеддинг последнего клика) через трилинейную комбинацию:

$$\hat{y} = \mathrm{softmax}\big(\tanh(W_s m_a) \odot \tanh(W_x x_t) \cdot \mathbf{E}^\top\big)\,. \tag{1.5}$$

SASRec [34] применила архитектуру Transformer-декодера (однонаправленное каузальное внимание) к последовательной рекомендации, используя механизм внимания на основе масштабированного скалярного произведения с позиционными эмбеддингами. Модель достигла на порядок более быстрого обучения по сравнению с CNN/RNN подходами.

BERT4Rec [6] адаптировала двунаправленный BERT к задаче через предсказание замаскированного токена, позволив каждому элементу учитывать контекст и слева, и справа. Маскирование с вероятностью $\rho \in [0.2, 0.6]$

генерирует больше обучающих сигналов по сравнению с авторегрессионным подходом.

1.2.2. Калибровка и эффективные альтернативы 2022–2025

Работа **gSASRec** [56] выявила проблему **overconfidence** в SASRec при обучении с BCE и негативным сэмплингом: предсказанные вероятности для позитивных товаров систематически завышены, что ухудшает top-K ранжирование. Решение — обобщённая BCE-потеря (gBCE) с параметром калибровки β и увеличенным числом негативов на каждый позитив. Архитектура идентична SASRec; меняется только процедура обучения.

FMLP-Rec [22] предложила полностью MLP-архитектуру, заменяющую self-attention обучаемыми фильтрами в частотной области: $\tilde{F}' = \tilde{F} \odot W$ в пространстве FFT, с обратным преобразованием для восстановления. Сложность снижается с $O(n^2)$ до $O(n \log n)$ при превосходстве над SASRec и BERT4Rec. в работе используется линейный механизм внимания с **LinRec** [44] используется L2-нормализованное линейное внимание, достигающее $O(N)$ сложности и применяемый как прямая замена стандартного слоя внимания.

Наиболее масштабная работа — **HSTU** [3] (Meta AI), переформулирующая рекомендации как задачу последовательной трансдукции с использованием Hierarchical Sequential Transduction Units. HSTU заменяет softmax-внимание поэлементной нормализацией (SiLU-гейтинг) и демонстрирует законы масштабирования до **триллиона параметров** с приростом 12.4% в онлайн A/B-тестах Meta. **Mamba4Rec** [46] адаптирует архитектуру Mamba (selective state space model) для последовательных рекомендаций с линейной сложностью.

1.2.3. Session-aware трансформеры: иерархическое кодирование сессий

Ключевым направлением развития трансформерных рекомендаторов стало введение явной двухуровневой иерархии сессий, позволяющей одновременно использовать всю историю прошлых сессий пользователя и контекст текущей активной сессии [60].

HRNN [60] — первая модель, явно разграничивающая внутрисессионную и межсессионную динамику для известного пользователя. Архитектура состоит из двух слоёв GRU: сессионного GRU, обрабатывающего объекты внутри сессии, и пользовательского GRU, обновляемого в конце каждой сес-

сии и кодирующего эволюцию предпочтений:

$$\mathbf{c}_{u,m} = \mathrm{GRU}_{\mathrm{usr}}\big(\mathbf{s}_{u,m},\ \mathbf{c}_{u,m-1}\big)\,, \tag{1.6}$$

где $\mathbf{s}_{u,m}$ — последнее скрытое состояние сессионного GRU за m-ю сессию. Эксперименты на данных XING показывают улучшение Recall@5 до +11% по сравнению с одноуровневыми RNN. Архитектурный шаблон «сессионный энкодер + надсессионный агрегатор» остаётся актуальным и для трансформерных моделей.

HCAN [1] переносит шаблон HRNN в трансформерную парадигму через явную двухуровневую архитектуру. На первом уровне каждая сессия кодируется независимо трансформерным энкодером:

$$\mathbf{s}_k = \mathrm{Transformer}_{\mathrm{item}}(\mathcal{B}_k)\,, \tag{1.7}$$

на втором уровне последовательность сессионных представлений $(\mathbf{s}_1, \ldots, \mathbf{s}_{M-1})$ обрабатывается трансформером сессий: $\mathbf{u} = \mathrm{Transformer}_{\mathrm{session}}(\mathbf{s}_1, \ldots, \mathbf{s}_{M-1})$. Оценка следующего объекта формируется через перекрёстное внимание между пользовательским вектором и объектами текущей сессии. Чёткое разделение градиентных путей упрощает интерпретацию модели и позволяет обучать уровни независимо.

PISA [85], разработанный для рекомендования музыки на Deezer, строит представления на уровне сессий, применяя когнитивную модель памяти ACT-R к взвешиванию прошлых сессий. Вес k-й сессии определяется экспоненциальным затуханием и частотой активации:

$$w_k \propto \exp(-d \cdot \Delta_k) \cdot f_k^{\gamma}, \tag{1.8}$$

где Δ_k — временной разрыв с момента k-й сессии, f_k — частота объектов, d, γ — обучаемые параметры. Модель явно учитывает повторные взаимодействия — феномен, типичный как для музыки, так и для e-commerce с периодически возвращающимися покупателями.

MOJITO [5] моделирует пользовательские предпочтения как смесь Гауссиан: каждая голова внимания специализируется на одном временно'м режиме (внутрисессионная активность, еженедельный ритм, сезонный тренд),

а шлюзовая сеть адаптивно комбинирует их в зависимости от контекста:

$$\mathrm{MixAttn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}; \mathbf{c}_t) = \sum_{k=1}^{K} g_k(\mathbf{c}_t)\ \mathrm{Attn}_k(\mathbf{Q}, \mathbf{K}, \mathbf{V}), \quad \sum_k g_k = 1. \tag{1.9}$$

Такая архитектура захватывает одновременно краткосрочную внутрисессионную динамику и долгосрочные сезонные паттерны, что особенно ценно для e-commerce с суточными, еженедельными и сезонными пиками активности.

CARCA [62] вводит перекрёстное внимание между всей историей пользователя и атрибутами объектов-кандидатов:

$$\hat{r}_{u,i} = \mathrm{CrossAttn}\Big(\mathbf{H}^{(L)},\ \mathrm{MLP}(\mathbf{a}_i)\Big), \tag{1.10}$$

где $\mathbf{H}^{(L)}$ — вся история пользователя после L трансформерных слоёв, $\mathbf{a}_i$ — вектор атрибутов кандидата (категория, цена, бренд). Это позволяет всем взаимодействиям истории «консультироваться» с атрибутами объекта-кандидата, а не только последнему взаимодействию, что выгодно отличает подход от стандартного скалярного произведения.

1.2.4. Самообучение и контрастивные методы для session-aware рекомендаций

S^3-Rec [66] предобучает трансформер путём максимизации взаимной информации между четырьмя типами корреляций: атрибут–объект, объект–объект, подпоследовательность–объект, последовательность–объект:

$$\mathcal{L}_{\mathrm{MI}} = -\mathbb{E}\Big[\log \sigma(f(e_i, a_i)) + \log\big(1 - \sigma\big(f(e_i, a_j)\big)\big)\Big]. \tag{1.11}$$

Предобучение на подпоследовательностях естественно обучает модель различать внутрисессионные и межсессионные паттерны; предобучение на атрибутах помогает в сценарии с разреженными историями новых пользователей.

DuoRec [10] диагностирует коллапс эмбеддингов в трансформерных рекомендаторах и предлагает двойную контрастивную стратегию: метод аугментации данных без учителя (одна история проходит дважды с разными dropout-масками) и метод аугментации данных с учителем (истории, содержащие общий объект, считаются семантически близкими). Потеря оптими-

зируется по NT-Xent:

$$\mathcal{L}_{\mathrm{CL}} = -\log \frac{\exp(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_j^+)/\tau)}{\sum_{k \neq i} \exp(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}. \tag{1.12}$$

Аугментации данных с учителем неявно кодирует общий сессионный контекст: пользователи, взаимодействовавшие с одним объектом в разных сессиях, должны иметь близкие представления.

BSARec [4] устраняет низкочастотное смещение стандартного самовнимания, добавляя обучаемую высокочастотную коррекцию через преобразование Фурье:

$$\mathrm{BSA}(\mathbf{H}) = \mathrm{Attn}(\mathbf{H}) + \alpha \cdot \mathcal{F}^{-1}(\mathrm{Rescale}(\mathcal{F}(\mathbf{H}))) \,. \tag{1.13}$$

Частотная декомпозиция естественно соответствует двухуровневой природе session-aware задачи: долгосрочные межсессионные предпочтения несут низкочастотный сигнал, краткосрочная внутрисессионная динамика — высокочастотный. BSARec без дополнительного контрастивного обучения превосходит DuoRec и FEARec [23] на шести стандартных бенчмарках.

1.3. Учёт временной информации: от интервалов до ротационных эмбеддингов

1.3.1. Временные интервалы в механизме внимания

TiSASRec [42] расширяет SASRec, явно моделируя как абсолютные позиции элементов, так и относительные временные интервалы между взаимодействиями. Интервалы между парами элементов i и j обрезаются до максимума k: $r_{ij} = \min(|t_i - t_j|, k)$ и отображаются в обучаемые эмбеддинги, модифицирующие attention:

$$\alpha_{ij} = \frac{q_i \cdot k_j + q_i \cdot r_{ij}^K}{\sqrt{d}}. \tag{1.14}$$

Комбинация абсолютных позиций и относительных временных интервалов превосходит использование каждого компонента по отдельности на разреженных и плотных датасетах.

1.3.2. Периодические кодирования времени

Time2Vec [35] предложила универсальное модельно-агностичное векторное представление времени, объединяющее линейный тренд и k периодических синусоидальных компонент:

$$\mathrm{t2v}(\tau)[i] = \begin{cases} \omega_i \tau + \varphi_i, & i = 0, \\ \sin(\omega_i \tau + \varphi_i), & 1 \le i \le k, \end{cases} \tag{1.15}$$

где ω_i, φ_i — обучаемые частоты и фазовые сдвиги.

1.3.3. Ротационные позиционные эмбеддинги в рекомендациях

Оригинальный **RoFormer** [65] кодирует позицию m через матрицу вращения $R_m = \mathrm{diag}(R_1(m\theta_1), \ldots)$, так что скалярное произведение $\langle R_m q, R_n k \rangle$ зависит только от относительной позиции $m - n$.

TO-RoPE [80] адаптирует RoPE для рекомендаций, совместно кодируя дискретный индекс и непрерывное время через три стратегии слияния: early fusion (совмещение углов в одной плоскости), split-by-dim (отдельные плоскости для индекса и времени) и split-by-head (выделение целых голов под каждый тип). **RecGRELA** [63] комбинирует RoPE с линейным attention и SiLU-гейтом для $O(N)$ сложности, устраняя необходимость в обучаемых таблицах позиционных эмбеддингов.

1.3.4. Устаревание эмбеддингов и временной спад

Проблема staleness (устаревания) эмбеддингов особенно актуальна для маркетплейсов с быстрым оборотом ассортимента. HSTU [3] использует логарифмическую бакетизацию разностей временных меток:

$$\mathrm{bucket}(a_{ij}) = \left\lfloor \frac{\log(\max(1, |a_{ij}|))}{0.301} \right\rfloor, \tag{1.16}$$

отображая каждый бакет в обучаемый скалярный bias в матрице внимания. Работа [20] показала, что при случайном хешировании **половина товаров покидает каталог в течение 6 дней**, делая эмбеддинги нестабильными; семантические идентификаторы на основе контентных признаков обеспечивают значительно более стабильные представления. Классический фундамент заложен Koren [37] в работе TimeSVD++, где латентные факторы пользователей

и товаров эволюционируют как функции времени.

1.4. Гибридные эмбеддинги и проблема dimensional collapse

1.4.1. Deep & Cross Network для формирования представлений

DCN [15] заменил ручное конструирование перекрёстных признаков алгоритмическим cross-network, где каждый слой вычисляет:

$$\mathbf{x}_{l+1} = \mathbf{x}_0 \cdot \mathbf{x}_l^\top \cdot \mathbf{w}_l + \mathbf{b}_l + \mathbf{x}_l. \tag{1.17}$$

DCN V2 [13] заменил весовой вектор полной матрицей $W_l \in \mathbb{R}^{d \times d}$:

$$\mathbf{x}_{l+1} = \mathbf{x}_0 \odot (W_l \cdot \mathbf{x}_l + \mathbf{b}_l) + \mathbf{x}_l. \tag{1.18}$$

Эмпирически обнаруженная **низкоранговая структура** обученных матриц мотивировала вариант DCN-Mix с mixture-of-low-rank-experts, достигающий сопоставимой точности при ~30% снижении параметров/FLOPs. **GDCN** [83] добавил информационные gates поверх каждого cross-слоя для селективной фильтрации шумных высокопорядковых взаимодействий. Другие ключевые гибридные архитектуры включают **Wide & Deep** [88] (Google Play), **NCF** [51] и **DLRM** [18] (Meta).

1.4.2. Dimensional collapse в рекомендательных моделях

Работа [54] идентифицировала **embedding collapse** — тенденцию эмбеддинговых матриц занимать низкоразмерное подпространство даже при увеличении размерности. Диагностика проводится через SVD-разложение $E = U\Sigma V^\top$; метрика Information Abundance = $\sum \sigma_i / \sigma_{\max}$ количественно оценивает степень коллапса. Авторы предложили архитектуру с несколькими эмбеддингами и специализированными модулями для различных типов взаимодействий.Chen et al. [24] показали, что контрастивные GNN-модели также подвержены коллапсу размерности, и предложили подход неконтрастивного обучения (nCL) в гиперсферическом пространстве.

1.4.3. Hash-based эмбеддинги для больших каталогов

Для каталогов с миллионами товаров полная эмбеддинговая таблица $O(M \times d)$ становится узким местом по памяти. **Compositional Embeddings**

[9] используют k малых таблиц с комплементарными разбиениями:

$$e(c) = \mathrm{OP}(T_1[h_1(c)], \ldots, T_k[h_k(c)]), \tag{1.19}$$

сжимая память до $O(k \cdot |S|^{1/k} \times D)$ — до **15× сжатие** при незначительной потере точности на Criteo/DLRM. **Deep Hash Embedding** [41] полностью заменяет таблицы нейросетью: $e(x) = \mathrm{DNN}(\mathrm{transform}(h_1(x), \ldots, h_k(x)))$, гарантируя нулевые коллизии хешей при 75% сжатии параметров. **Frequency-Based Double Hashing** [47] использует двойное хеширование с частотно-зависимым распределением ёмкости.

1.4.4. Иерархические и композитные представления товаров

Описанные выше методы сжатия (хеширование, двойное хеширование) преследуют инженерную цель — уменьшение памяти. Однако каталоги маркетплейсов, как правило, обладают естественной иерархической структурой (K уровней: корневая категория $\supset$ подкатегория $\supset \ldots \supset$ товар), которую стандартная таблица представлений игнорирует. Два товара одной подкатегории обучаются с нуля независимо друг от друга, что порождает проблемы холодного старта для редких товаров и избыточность параметров.

LightFM [39] представляет товар как сумму обучаемых представлений его признаков (идентификатор, категория, теги):

$$e_{\text{item}} = \sum_{f \in \mathcal{F}_{\text{item}}} e_f. \tag{1.20}$$

Если признаки включают категориальные индикаторы, товары одной категории разделяют компоненту представления, что обеспечивает перенос знаний при холодном старте. Ограничения: суммирование не позволяет контролировать вклад уровней иерархии, а модель основана на матричной факторизации, а не на трансформерной архитектуре.

HGE (Hierarchical Graph Embedding) [70] использует граф товарной иерархии и выполняет графовую свёртку снизу вверх по уровням:

$$\mathbf{E} = \mathbf{E} + \mathrm{HGE}(\mathbf{E}, G), \tag{1.21}$$

где G — граф иерархии. HGE показала улучшение в сценарии холодного

старта, однако графовое распространение в каждом батче затрудняет распределённое обучение и масштабирование.

TIGER [64] представляет товар последовательностью дискретных токенов, полученных через остаточное векторное квантование (RQ-VAE) из контентных признаков. Первые коды описывают грубый семантический кластер, последующие уточняют. Развитие этой идеи — **Semantic ID prefix-ngram** [68], внедрённый в промышленную систему Meta: для Semantic ID (c_1, c_2, c_3) создаются prefix-признаки (униграмма c_1, биграмма (c_1, c_2), триграмма (c_1, c_2, c_3)), каждый со своей таблицей представлений, результат суммируется. В online A/B тесте дисперсия предсказаний для редких товаров снизилась на 43%.

Ключевое наблюдение: все перечисленные подходы используют *суммирование* для объединения иерархических компонент. Это архитектурно обусловлено совместимостью с DLRM [18], где попарное скалярное произведение признаков требует одинаковой размерности. В контексте последовательных рекомендаций данное ограничение не действует: представление товара подаётся непосредственно в трансформер, что открывает возможность для *конкатенации* компонент разных уровней иерархии с явным контролем размерностей (подробнее — в разделе 2.2.2).

1.5. Контекстуальная информация: запросы, типы действий, сессионные токены

1.5.1. Учёт поисковых запросов в последовательных рекомендациях

Query-Aware Sequential Recommendation [61] — первая работа, формализующая совместное моделирование поисковых запросов и последовательностей товаров. Модель организует запросы и товары как гетерогенные последовательности и применяет self-attention по объединённому представлению; разные запросы над одной последовательностью дают разные рекомендации.

JSR [89] совместно обучает модели поиска и рекомендаций через общие матрицы эмбеддингов W (пользователи) и E (товары), оптимизируя объединённую функцию потерь $L = L_{IR} + L_{RS}$.

UDITSR [87] моделирует двойные интенты (явные из поиска, неявные

из рекомендаций) через граф двух сценариев с контрастивной потерей.

SynerGen [76] — первая decoder-only генеративная модель, поддерживающая и query-aware поиск, и query-free рекомендации в едином backbone с time-aware rotary positional embedding.

1.5.2. Разделение типов действий (multi-behavior recommendation)

В e-commerce пользователь совершает различные действия: клик, добавление в корзину, покупка, просмотр. **MB-STR** [55] использует Transformer с behavior-type-specific routing через различные feed-forward слои и sparse Mixture-of-Experts для кодирования гетерогенных последовательных паттернов. Обучение ведётся через behavior-aware masked item prediction: товары маскируются, а типы действий остаются видимыми.

NMTR [53] формализует каскадные отношения между поведениями (view → cart → purchase) как связанные задачи multi-task обучения. **MBSRec** [49] захватывает зависимости между поведениями через multi-head self-attention с взвешенной BCE-потерей. Обзор Kim et al. [2] систематизирует всю область в трёхэтапный фреймворк: Data Modeling, Encoding, Training.

1.5.3. Негативная выборка из просмотренных товаров

Ding et al. [32] в работе «Improving Implicit Recommender Systems with View Data» установили **трёхуровневую иерархию предпочтений**: purchased > viewed > non-viewed. Просмотренные, но некупленные товары служат информативными hard negatives — сложнее случайных, но мягче истинных негативов.

Shi et al. [84] впервые дали теоретическое обоснование hard negative sampling, доказав, что BPR с dynamic negative sampling является точным оценщиком OPAUC. Prakash et al. [57] оценили стратегии негативного сэмплирования специфично для SASRec-архитектуры, выявив, что адаптивная смешанная стратегия достигает наилучших результатов.

1.5.4. Сессионные разделительные токены

Seol, Ko, Lee [69] в работе «Exploiting Session Information in BERT-based Session-aware Sequential Recommendation» предложили три механизма включения сессионной информации в BERT4Rec:

1. **Session Token (ST)** — обучаемый специальный токен, вставляемый меж-

ду сессиями (аналог [SEP] в NLP);

2. **Session Segment Embedding (SSE)** — обучаемый эмбеддинг уровня сессии, добавляемый к каждому элементу: $\mathbf{x} = \mathbf{IE}_i + \mathbf{PE}_p + \mathbf{SSE}_j$;

3. **Time-Aware Self-Attention (TAS)** — временное кодирование промежутков между взаимодействиями.

Все три подхода улучшают vanilla BERT4Rec/SASRec без сложных иерархических архитектур. **Transformers4Rec** [86] (NVIDIA) предоставляет инфраструктуру для применения NLP-концепций (включая специальные токены) к рекомендациям, выиграв два соревнования по session-based рекомендациям.

1.5.5. Моделирование эволюции интересов пользователя

Интент пользователя не является статичным: он претерпевает непрерывную эволюцию как в пределах одной сессии — от этапа формирования потребности к целенаправленному поиску — так и на межсессионном горизонте, под влиянием сезонных факторов и изменений жизненного контекста. Данное явление получило наименование *interest drift* и составляет самостоятельное направление исследований.

DIN (Deep Interest Network) [17] ввёл понятие *адаптивного активационного механизма*: вместо агрегации всей пользовательской истории в единый вектор модель вычисляет вес релевантности каждого исторического взаимодействия относительно конкретного товара-кандидата $\mathbf{v}_a$:

$$\mathbf{e}_u = \sum_{i \in \mathcal{H}^u} a(\mathbf{v}_i,\, \mathbf{v}_a) \cdot \mathbf{v}_i, \qquad a(\mathbf{v}_i, \mathbf{v}_a) = \sigma(\mathrm{MLP}([\mathbf{v}_i;\, \mathbf{v}_a;\, \mathbf{v}_i \odot \mathbf{v}_a]))\,. \tag{1.22}$$

Тем самым формируется *инстанс-зависимое* представление пользователя: его эффективный профиль адаптируется к каждому кандидату независимо, что принципиально отличается от инстанс-независимых методов усредняющего пулинга.

DIEN (Deep Interest Evolution Network) [16] расширяет DIN введением явного механизма эволюции интересов. Двухуровневая архитектура объединяет *слой извлечения интересов* (GRU) и *слой эволюции интересов* (AUGRU — GRU с внимания-взвешенным update gate), позволяя отслеживать только ту часть траектории интересов, которая релевантна текущему

кандидату:

$$\mathbf{h}'_t = (1 - \mathbf{u}'_t) \odot \mathbf{h}'_{t-1} + \mathbf{u}'_t \odot \tilde{\mathbf{h}}'_t, \qquad \mathbf{u}'_t = a(\mathbf{h}_t, \mathbf{v}_a) \cdot \mathbf{u}_t, \tag{1.23}$$

где $\mathbf{u}_t$ — стандартный update gate GRU, масштабируемый скором внимания к текущему кандидату. В контексте session-aware задачи DIEN формализует ключевую гипотезу: не все прошлые сессии одинаково релевантны текущему намерению пользователя.

SIM (Search-based Interest Model) [67] решает задачу масштабируемого моделирования долгосрочной истории для пользователей с 10^4 и более взаимодействиями. На первом этапе из всей истории жёстким или мягким поиском (GSU/ESU) извлекаются топ-K наиболее схожих с кандидатом взаимодействий; на втором к ним применяется механизм внимания с временны'м кодированием. Промышленное развёртывание в системе Alibaba подтвердило значимый прирост качества при масштабировании истории без увеличения вычислительной сложности инференса.

1.5.6. Disentanglement интентов: разделение устойчивых и волатильных компонент

Фундаментальная проблема моделирования интента — декомпозиция пользовательских предпочтений на *инвариантную* составляющую (устойчивые долгосрочные интересы, не зависящие от текущего контекста) и *контекстно-зависимую* составляющую (волатильные краткосрочные намерения, специфичные для текущей сессии). Методы без явного разделения систематически смешивают эти сигналы, что приводит к ошибкам интерпретации.

CauseRec [8] применяет инструментарий каузального вывода для диентангленте представления пользователя на *стабильный интерес* $\mathbf{z}_s$ и *нестабильный интерес* $\mathbf{z}_u$. Контрфактуальное обучение с интервенциями на историю взаимодействий обеспечивает статистическую независимость компонент $\mathbf{z}_s \perp\!\!\!\perp \mathbf{z}_u$ и устойчивость стабильного интереса к случайным возмущениям сессионного контекста.

ICLRec (Intent Contrastive Learning for Sequential Recommendation) [33] моделирует множество латентных интентов через прототипическое обучение: K кластерных центроидов $\{\mathbf{c}_k\}$ в пространстве пользовательских эмбеддингов представляют дискретные прототипы намерений. Контрастивная цель

максимизирует согласованность между представлением пользователя и его ближайшим прототипом:

$$\mathcal{L}_{\text{intent}} = -\log \frac{\exp(\mathbf{z}_u \cdot \mathbf{c}_{k^*}/\tau)}{\sum_{j=1}^{K} \exp(\mathbf{z}_u \cdot \mathbf{c}_j/\tau)}, \qquad k^* = \operatorname*{argmax}_k \mathbf{z}_u \cdot \mathbf{c}_k. \tag{1.24}$$

Совместное обучение с основной задачей предсказания следующего товара обеспечивает семантическую интерпретируемость кластеров и прирост NDCG@10 на 2.5–5% на бенчмарках Amazon и Yelp.

CORE (Consistent Representation Learning for Session-based Recommendation) [1 постулирует требование *семантической согласованности*: представление сессии и представления составляющих её товаров должны принадлежать единому семантическому пространству. Это ограничение гарантирует, что сессионный вектор остаётся интерпретируемым в терминах товарных эмбеддингов, а не является произвольной скрытой переменной другого пространства.

1.5.7. Обогащение контекста через внешние структурированные знания

Идентификаторные модели (ID-based) ограничены в способности к семантическому обобщению: близость двух товаров определяется исключительно статистикой совместных появлений в историях пользователей, тогда как содержательная семантическая близость — принадлежность к одной категории, схожие технические характеристики, единый производитель — остаётся скрытой. Для преодоления этого ограничения применяется обогащение признаковых пространств через графы знаний, категориальные иерархии и атрибутивные схемы.

KGAT (Knowledge Graph Attention Network) [36] рассматривает взаимодействия пользователей и товаров как специальный тип отношений в гетерогенном графе знаний $\mathcal{G} = \{(h, r, t)\}$. Рёберно-специфичный механизм внимания взвешивает соседей по типу отношения:

$$\pi(h, r, t) = (\mathbf{W}_r \mathbf{e}_t)^\top \tanh(\mathbf{W}_r \mathbf{e}_h + \mathbf{e}_r), \tag{1.25}$$

где $\mathbf{W}_r$ — матрица проекции, специфичная для типа отношения r. Послойное распространение по графу формирует обогащённые эмбеддинги, отражающие семантику категориальных связей, атрибутов и производителей. В session-aware контексте это позволяет устанавливать семантическое родство между

товарами, посещёнными в разных сессиях.

KGIN (Knowledge Graph-based Intent Network) [40] вводит понятие *интент-пути*: цепочка отношений $(r_1, r_2, \ldots, r_L)$ от пользователя до товара интерпретируется как атомарное намерение. Агрегация по всем таким путям порождает интент-специфичное представление пользователя, обеспечивающее интерпретируемость рекомендаций через структуру намерений:

$$\mathbf{p}_{(r_1,\ldots,r_L)} = \mathbf{e}_{r_1} \odot \mathbf{e}_{r_2} \odot \cdots \odot \mathbf{e}_{r_L}, \qquad \mathbf{u}_{\text{intent}} = \sum_{\text{path}} \beta_{\text{path}} \cdot \mathbf{p}_{\text{path}}. \tag{1.26}$$

Подход открывает перспективу использования онтологий товарных каталогов (иерархии категорий, атрибутивные схемы маркетплейса) как источника структурированного контекста для уточнения пользовательского интента на уровне сессии.

1.6. Графовые подходы к сессионным рекомендациям

1.6.1. От SR-GNN к глобальному контексту

SR-GNN [71] — семинальная работа, впервые моделирующая сессионные последовательности как ориентированные графы. Из сессии $s = [v_{s,1}, \ldots, v_{s,n}]$ строится граф $\mathcal{G}_s = (\mathcal{V}_s, \mathcal{E}_s)$, где рёбра $(v_{s,i-1}, v_{s,i})$ нормализуются по исходящей степени. Gated Graph Neural Network обновляет эмбеддинги через механизм гейтов:

$$\mathbf{v}_i^l = (1 - \mathbf{z}_t) \odot \mathbf{v}_i^{l-1} + \mathbf{z}_t \odot \tilde{\mathbf{v}}_i^l. \tag{1.27}$$

Представление сессии $\mathbf{s}_h = W_3[\mathbf{s}_l; \mathbf{s}_g]$ объединяет локальный (последний клик) и глобальный (attention-взвешенная сумма) компоненты.

GCE-GNN [25] устранила ограничение моделирования только внутрисессионных переходов, введя **два уровня эмбеддингов**: session-level (через GGNN по графу сессии) и global-level (через session-aware attention по глобальному графу всех сессий). Агрегация двух уровней выполняется через soft attention.

TAGNN [78] добавила target-aware attention, где представление сессии адаптивно меняется в зависимости от целевого товара-кандидата: $\mathbf{s}_t = \sum \alpha_i \cdot \mathbf{v}_i$, где $\alpha_i = \text{softmax}(f(\mathbf{v}_i, \mathbf{v}_t))$.

GC-SAN [26] комбинирует GNN (для локальных зависимостей) с multi-

layer self-attention (для дальних зависимостей), финальное представление — взвешенная комбинация $\mathbf{s}_h = \omega \cdot \mathbf{s}_a + (1 - \omega) \cdot \mathbf{v}_n$.

1.6.2. Графовая коллаборативная фильтрация

NGCF [52] предложил embedding propagation на двудольном графе «пользователь–товар» для кодирования коллаборативного сигнала высокого порядка:

$$m_{u \leftarrow i} = \frac{1}{\sqrt{|N_u|}\sqrt{|N_i|}} \left(W_1 \mathbf{e}_i + W_2 (\mathbf{e}_i \odot \mathbf{e}_u) \right). \tag{1.28}$$

LightGCN [43] через ablation-анализ NGCF обнаружил, что feature transformation и нелинейная активация не только не помогают, но вредят в задаче CF. LightGCN сохраняет только **линейное распространение с агрегацией соседей** и взвешенную сумму по слоям:

$$\mathbf{e}_u = \sum_{k=0}^{K} \alpha_k \cdot \mathbf{e}_u^{(k)}, \quad \alpha_k = \frac{1}{K+1}, \tag{1.29}$$

давая ~16% прирост над NGCF.

1.6.3. Гетерогенные графы

HG-GNN [28] строит **гетерогенный глобальный граф** с двумя типами узлов (пользователи, товары) и тремя типами рёбер (исторические взаимодействия, внутрисессионные переходы, глобальные ко-вхождения). Meta-path-based агрегация обучает Current Preference Encoder и Historical Preference Encoder, объединяемые в Personalized Session Encoder. Фундамент гетерогенных графовых сетей заложен в **HAN** [29] с иерархическим attention: node-level (важность соседей по мета-пути) и semantic-level (важность различных мета-путей).

1.7. Архитектурные улучшения для промышленных систем

1.7.1. Mixture of Experts в рекомендациях

MMoE [48] заменил shared-bottom архитектуру multi-task обучения общими экспертами с task-specific gating:

$$y_k = h_k\left(\sum_i g_{k,i}(x) \cdot f_i(x) \right), \quad g_k(x) = \mathrm{softmax}(W_{g_k} \cdot x). \tag{1.30}$$

PLE [59] расширил MMoE совместными и task-specific экспертами с прогрессивной послойной экстракцией. Прорыв в балансировке нагрузки экспертов достигнут в работе DeepSeek [19]: к скорам маршрутизации добавляется обучаемый bias b_i для каждого эксперта, корректируемый по загрузке (если эксперт перегружен — b_i уменьшается на γ, иначе увеличивается). Критически, bias влияет только на маршрутизацию, не на gate-значения, обеспечивая нулевые интерференционные градиенты. Метод развёрнут в **DeepSeek-V3** (671B параметров, 37B активных).

1.7.2. TorchRec и jagged tensors

TorchRec [82] (Meta) — PyTorch-библиотека с примитивами разреженности и параллелизма для рекомендаций промышленного масштаба. Ключевая структура данных — **KeyedJaggedTensor (KJT)**: эффективное хранение категориальных признаков переменной длины через непрерывный массив значений с массивом смещений, исключающее потери на padding. Поддерживает гибридный data+model параллелизм с table-wise, row-wise, column-wise шардированием эмбеддинговых таблиц. Используется для обучения моделей **более 3 триллионов параметров** в Meta. **Jagged Flash Attention** обеспечивает 9× ускорения и 22× сжатия памяти по сравнению с dense attention.

1.7.3. Knowledge distillation и LoRA

Knowledge distillation в рекомендациях включает Ranking Distillation [79], DE-RRD [14], Topology Distillation [81] и Privileged Features Distillation [58] — передачу знаний из признаков, доступных при обучении, но недоступных при сервинге.

LoRA [45] вводит низкоранговую адаптацию $W = W_0 + BA$, где $B \in \mathbb{R}^{d\times r}$, $A \in \mathbb{R}^{r\times k}$, $r \ll \min(d, k)$, сокращая обучаемые параметры в 10000× для GPT-3. Принцип низкоранговости перекликается с DCN V2 (низкоранговые cross-слои), compositional embeddings (факторизация таблиц) и проблемой dimensional collapse. Применение LoRA к рекомендациям активно развивается в контексте федеративных рекомендательных систем [21] и fine-tuning LLM-based рекомендателей.

1.8. Наборы данных для оценки

Для экспериментальной оценки предлагаемого метода выбраны четыре публично доступных набора данных, охватывающих различные сценарии e-commerce рекомендования: стандартные бенчмарки последовательной рекомендации, мультиповеденческие данные и датасеты с поисковыми запросами.

1.8.1. Amazon Reviews

Семейство наборов данных **Amazon Reviews** [31] содержит взаимодействия пользователей с товарами нескольких категорий интернет-магазина Amazon. Данные включают оценки, текстовые отзывы, временны'е метки и богатые метаданные товаров (категория, цена, бренд, текстовое описание). Для экспериментов используются две категории с контрастными характеристиками разреженности:

- **Amazon-Beauty** — разреженная категория (~22k пользователей, ~12k товаров), типична для cold-start сценариев;
- **Amazon-Sports** — умеренная плотность (~36k пользователей, ~18k товаров), стандартный бенчмарк для сравнения с SASRec, BERT4Rec, DuoRec, BSARec.

Сессии конструируются из хронологических последовательностей взаимодействий путём разбивки по временному порогу (разрыв > 30 минут — новая сессия). Для оценки применяется протокол leave-one-out: последнее взаимодействие каждого пользователя отводится под тест, предпоследнее — под валидацию.

1.8.2. MovieLens-1M

MovieLens-1M [27] — классический бенчмарк рекомендательных систем, содержащий около 1 миллиона оценок 6 040 пользователей по 3 706 фильмам с временны'ми метками. Несмотря на специфику предметной области (кино), датасет широко используется для воспроизводимого сравнения с иерархическими моделями: HRNN [60] и Session-aware BERT4Rec [69] первично оценивались на этом наборе. Плотность данных (~4.5% заполненности матрицы взаимодействий) позволяет проверить поведение модели при достаточном количестве обучающих сигналов. Сессии разбиваются аналогично

Amazon по временному порогу.

1.8.3. Tmall (IJCAI-15)

Tmall — набор данных крупного китайского маркетплейса Alibaba Tmall, предоставленный для конкурса IJCAI-15. Содержит журналы поведения авторизованных пользователей с четырьмя типами действий: клик, добавление в избранное, добавление в корзину, покупка. Наличие полного спектра поведенческих типов делает датасет незаменимым для оценки multi-behavior компонента. Ключевые характеристики: ~884k пользователей, ~1.1M товаров, ~54M событий. Временны'е метки позволяют восстановить структуру сессий; известные идентификаторы пользователей обеспечивают полную применимость session-aware постановки.

1.8.4. Coveo SIGIR eCommerce Dataset

Coveo SIGIR eCommerce Dataset [77] — единственный из рассматриваемых наборов, содержащий как поисковые запросы, так и поведенческие события. Датасет опубликован в рамках задачи SIGIR 2021 eCom Data Challenge и включает реальные данные e-commerce платформы: поисковые запросы пользователей, просмотры страниц товаров, добавления в корзину и покупки в рамках явно размеченных сессий.

Основные характеристики:

- Явные границы сессий (session ID присвоены в исходных данных);
- Поисковые запросы на естественном языке, ассоциированные с событиями;
- Несколько типов событий (pageview, detail, add, purchase);
- Метаданные товаров: категория, цена, описание.

Этот датасет является основным для оценки query-aware компонента предлагаемой архитектуры, поскольку позволяет верифицировать, насколько явное включение поисковых запросов улучшает качество рекомендаций по сравнению с моделями, опирающимися только на поведенческую историю.

1.8.5. Сравнительная характеристика датасетов

Для всех датасетов применяется единый протокол предобработки: удаление пользователей с менее чем 5 взаимодействиями (стандартный порог

Таблица 1.1 – Сравнение наборов данных для экспериментальной оценки.

Датасет	Пользователи	Товары	События	Сессии	Multi-behavior	Запр
Amazon-Beauty	22 363	12 101	198 502	конструируются	–	–
Amazon-Sports	35 598	18 357	296 337	конструируются	–	–
MovieLens-1M	6 040	3 706	1 000 209	конструируются	–	–
Tmall	884 531	1 090 390	54 925 331	конструируются	✓	–
Coveo SIGIR	~1M	~1.6M	~50M	явные	✓	✓

5-core), нормализация временны'х меток, разбивка 80/10/10 для трейна, валидации и теста по времени.

1.9. Метрики оценки качества рекомендаций

Для количественной оценки качества рекомендательных моделей в задаче предсказания следующего товара используются метрики ранжирования, вычисляемые по полному каталогу товаров [38]. Оценка по подвыборке негативов намеренно исключается, поскольку приводит к несогласованным рейтингам моделей [38].

1.9.1. Основные метрики ранжирования

Hit Rate@K (HR@K) измеряет долю тестовых запросов, для которых целевой товар попал в первые K позиций рекомендованного списка:

$$\mathrm{HR@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \mathbf{1}\big[\mathrm{rank}(i_u^*) \le K\big], \tag{1.31}$$

где i_u^* — целевой товар пользователя u, $\mathrm{rank}(i_u^*)$ — его позиция в ранжированном списке. При единственном целевом товаре (leave-one-out) HR@K совпадает с Recall@K.

Normalized Discounted Cumulative Gain@K (NDCG@K) учитывает позицию целевого товара в списке через логарифмическое дисконтирование:

$$\mathrm{NDCG@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{\mathbf{1}\big[\mathrm{rank}(i_u^*) \le K\big]}{\log_2(\mathrm{rank}(i_u^*) + 1)}. \tag{1.32}$$

Рекомендация на первой позиции даёт максимальный вклад $1/\log_2(2) = 1$; рекомендация на позиции K — минимальный в пределах top-K.

Mean Reciprocal Rank (MRR) усредняет обратные ранги целевых то-

варов по всем пользователям:

$$\mathrm{MRR} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{1}{\mathrm{rank}(i_u^*)}. \tag{1.33}$$

MRR особенно чувствителен к точным попаданиям на первых позициях и дополняет NDCG при анализе поведения модели в верхней части рейтинга.

В экспериментах используются значения $K \in \{10, 20\}$ как наиболее распространённые в литературе по session-aware рекомендованию [4; 6; 10; 34].

1.9.2. Дополнительные метрики для session-aware анализа

Помимо стандартных метрик ранжирования, для углублённого анализа предлагается вычислять следующие показатели.

Метрики в разрезе длины истории. Пользователи разбиваются на группы по числу прошлых сессий: короткая история ($\leq$ 3 сессий), средняя (4–10) и длинная ($>$ 10). Раздельный расчёт HR@10 и NDCG@10 по группам позволяет оценить способность модели работать как в cold-start сценарии, так и при богатой долгосрочной истории.

Метрики по типу поведения (для Tmall). На датасете Tmall целевым событием является покупка; метрики вычисляются отдельно по событиям типа «покупка», что отражает бизнес-релевантную задачу предсказания конверсии.

Метрики для query-aware сценария (для Coveo). На датасете Coveo дополнительно вычисляется HR@10 в подмножестве сессий, начинающихся с поискового запроса, против сессий без запроса. Это позволяет количественно оценить вклад query-aware компонента в качество рекомендаций.

1.9.3. Протокол оценки

Во всех экспериментах применяется единый протокол:

1. **Разбивка по времени**: обучающая, валидационная и тестовая выборки формируются хронологически в соотношении 80/10/10, исключая утечку данных из будущего.

2. **Leave-last-out**: последнее взаимодействие каждого пользователя отводится под тест, предпоследнее — под валидацию.

3. **Полный каталог**: метрики вычисляются по всем товарам каталога без отбора негативов.

4. **5-core фильтрация**: удаляются пользователи и товары с менее чем 5 взаимодействиями.

5. **Повторяемость**: для каждого эксперимента фиксируются случайные зёрна (random seed); результаты усредняются по 3 запускам.

1.10. Функции потерь и стратегии отбора негативных примеров

Краткий обзор функций потерь в разделе 1.1.2 намеренно ограничивался формальными определениями. Однако при переходе от небольших бенчмарков к промышленным системам с каталогами в миллионы товаров и десятками тысяч отобранных негативов за шаг обучения картина усложняется: выбор функции потерь и стратегии отбора негативных примеров становится самостоятельной исследовательской задачей [57]. Настоящий раздел систематизирует ключевые направления этой области и определяет нишу, которую занимает предлагаемый в главе 2 подход.

1.10.1. Корень проблемы: конфликт лёгких и ложных негативов

При равномерном отборе негативов из большого каталога подавляющее большинство попавших в мини-батч товаров нерелевантны пользователю очевидным образом — их логиты заведомо низки, а per-item-градиент мал. Суммарный же вклад тысяч таких «лёгких» негативов численно подавляет сигнал от редких информативных примеров: модель тратит ёмкость на закрепление тривиальных решений вместо обучения тонким предпочтениям [74].

Естественная реакция — сместить выборку в сторону *трудных* негативов: тех, чьи логиты близки к логиту позитива. Жёсткий отбор (top-k mining, DNS) даёт максимально информативный сигнал в average-case, однако порождает принципиальную проблему при имплицитной обратной связи: наиболее релевантные ненаблюдаемые товары одновременно являются наиболее *ложными* негативами (false negatives) — вещами, которые пользователь купил бы, но ещё не купил. Обучение на таких примерах инвертирует сигнал и ухудшает качество рекомендаций [74]. Это противоречие между информативностью и надёжностью негативов определяет архитектуру решений во всей области.

1.10.2. Отбор на стороне сэмплера

Первое семейство методов решает задачу на уровне *выбора*, а не *взвешивания* негативов.

Динамический отбор (DNS). Вместо случайного негатива берётся наиболее высоко оценённый моделью в текущий момент. Подход ускоряет сходимость, но уязвим именно к false negatives: модель по мере обучения всё чаще выдвигает в топ популярные релевантные товары.

SRNS. Ding et al. [74] предложили явно учитывать шум выборки: взаимодействие помечается как надёжный негатив только если его оценка устойчиво низка на нескольких последних шагах, тогда как нестабильно высокооцениваемые кандидаты отфильтровываются как возможные false negatives. Это позволяет сохранить большую часть выгоды от hard mining, не принося в жертву надёжность.

AdaSIR и SimANS. В задаче плотного поиска Zhou et al. [73] обнаружили, что ни слишком лёгкие, ни слишком трудные негативы не дают оптимального сигнала: наиболее полезны «неоднозначные» полутрудные (ambiguous semi-hard) кандидаты. SimANS формализует эту идею через явный критерий отбора по близости логита негатива к логиту позитива. Аналогичный принцип в коллаборативной фильтрации реализует AdaSIR через importance resampling.

1.10.3. Объективы с внутренней конкуренцией между негативами

Второе семейство не меняет сэмплер, а перестраивает сам обучающий сигнал так, чтобы негативы конкурировали друг с другом.

BPR-max и TOP1-max. Hidasi и Karatzoglou [30] заменили в сессионных рекомендациях стандартный BPR на его смягчённые варианты. В BPR-max функция потерь представляет собой взвешенную softmax-сумму по всем негативам в мини-батче:

$$\mathcal{L}_{\text{BPR-max}} = -\log \sum_j \operatorname{softmax}(s_j^-) \cdot \sigma(s^+ - s_j^-), \tag{1.34}$$

что автоматически концентрирует градиент на наиболее трудных негативах без явного top-k отбора. BPR-max стал первым механическим прообразом мягкого score-aware взвешивания внутри фиксированного набора негативов.

Sampled Softmax. В задаче рекомендаций sampled softmax сводит все N негативов к знаменателю нормировки, создавая естественную конкуренцию:

$$\mathcal{L}_{\text{SS}} = -s^{+} + \log \sum_{j=1}^{N} \exp(s_j^{-}). \tag{1.35}$$

Ряд работ показал, что при достаточно большом N sampled softmax превосходит BCE как по точности, так и по согласованности с top-K метриками [11]. Важный побочный эффект: градиент по каждому негативу автоматически пропорционален его softmax-весу — то есть softmax неявно реализует монотонное score-aware взвешивание, которое BPR-max делал явным.

BSL и PSL. Ряд более поздних работ показал, что именно это монотонное взвешивание является уязвимым местом softmax-семейства. Чем сильнее модель, тем выше логиты false negatives — и тем больший вес они получают в знаменателе, создавая обратную связь, систематически усиливающую ошибочный сигнал. BSL и PSL предлагают коррекции этого эффекта: разреженную нормировку и нелинейный температурный контроль.

1.10.4. Калибровка BCE и согласование с top-K

Третье семейство остаётся в рамках pointwise BCE, но модифицирует его, чтобы устранить несоответствие между минимизируемой функцией и реальными метриками ранжирования.

gBCE / gSASRec. Petrov и Macdonald [56] показали, что стандартный BCE при отборе нескольких негативов систематически завышает уверенность модели на позитивах. Авторы предложили β-преобразование логита позитива ($\hat{y}^{+} \leftarrow \beta \cdot s^{+}$, $\beta < 1$), которое калибрует вероятности и улучшает Recall@K без изменения стратегии взвешивания негативов — то есть gBCE работает на стороне позитива, оставляя равномерное взвешивание негативов нетронутым.

Top-K-aware объективы. Ряд работ 2024 года предложил суррогатные функции, явно оптимизирующие NDCG или частичный AUC (lower-left partial AUC, LLPAUC), чтобы устранить известный разрыв между BCE/BPR и финальными метриками ранжирования. Эти подходы принципиально меняют форму градиента, но требуют тщательной регуляризации, так как нерегуляризованная оптимизация top-k суррогатов нестабильна на больших каталогах.

1.10.5. Надёжность негативов и коррекция ложных срабатываний

Четвёртое семейство сосредоточено на явной работе с ненадёжностью негативов в условиях имплицитной обратной связи.

CCR для плотного поиска. Contrastive Confidence Regularization явно штрафует за высокую уверенность на негативах, уровень логита которых приближается к позитиву, тем самым создавая защитную зону вокруг заведомо неоднозначных кандидатов.

Correct and Weight (CW). Метод исходит из противоположной гипотезы относительно SRNS: вместо того чтобы изолировать надёжные hard negatives, CW *усиливает* градиент именно от надёжно-негативных кандидатов (с устойчиво низким логитом) и ослабляет от неоднозначных. Это прямая альтернатива любому hard mining и важная точка сравнения для экспериментов.

DSL. Dynamic Softmax Loss (2026) явно вводит per-negative веса, зависящие одновременно от трудности (logit) и семантической близости к позитиву, удерживая при этом базовый objective в softmax-семействе. DSL представляет собой ближайший современный аналог механики взвешивания, применяемой в предлагаемом методе.

1.10.6. Позиционирование предлагаемого подхода

Карта области позволяет точно описать нишу, которую занимает метод из главы 2.

Все перечисленные семейства решают проблему легких / ложных негативов одним из трёх ходов: (1) меняют сэмплер, (2) переходят к pairwise или listwise/softmax objective, (3) корректируют false negatives через confidence-фильтры. Направление *pointwise BCE + мягкое score-aware перераспределение градиента внутри фиксированного набора отобранных негативов* менее исследовано: gBCE решает проблему на стороне позитива, BPR-max и DSL делают это в softmax-семействе, а не в BCE.

Ближайшим механическим прообразом остаётся BPR-max: он явно строит softmax-веса по негативным логитам. Предлагаемый Cauchy BCE (2.2.4) переносит эту идею в BCE-совместимый формат с двумя принципиальными отличиями. Во-первых, весовая функция *немонотонна*: максимум веса приходится не на hardest negative, а на semi-hard зону, что напрямую адресует

проблему false negatives без явной фильтрации. Во-вторых, веса вычисляются с операцией `detach`: приоритизация отделена от оптимизируемого параметра, что разрывает контур обратной связи между весами и логитами — известный источник нестабильности в softmax-weighted BCE [56].

1.11. Выводы по главе

Проведённый анализ литературы выявляет несколько ключевых наблюдений. Во-первых, ни одна существующая работа не объединяет все четыре типа контекстных сигналов — **поисковые запросы, типы действий, сессионные границы и временную информацию** — в единой архитектуре.

Систематизация подходов к обучению при большом числе негативов (раздел 1.10) показала, что существующие методы решают задачу легких и ложных негативов тремя путями: изменением сэмплера, переходом к pairwise/listwise objective или явной фильтрацией false negatives. Направление pointwise BCE с мягким немонотонным перераспределением градиента по набору отобранных негативов остаётся малоисследованным; ближайшие аналоги — BPR-max и DSL — реализуют схожую идею в softmax-семействе, а не в BCE-совместимом формате. Каждый из этих сигналов исследован отдельно [42; 55; 61; 69], но их синергия остаётся неисследованной.

Во-вторых, применение RoPE к рекомендациям находится на ранней стадии [63; 80], и его комбинация с сессионной структурой и multi-behavior моделированием представляет новую исследовательскую возможность.

В-третьих, проблема dimensional collapse при масштабировании моделей [54] и embedding staleness при быстром обороте каталога [20] требуют архитектурных решений, специфичных для e-commerce с его динамичным ассортиментом.

Наконец, приёмы из LLM-мира — **MoE с auxiliary-loss-free балансировкой** [19], **LoRA для инкрементального обучения** [45], **flash attention для jagged данных** [82] — создают инфраструктуру для моделей следующего поколения, способных обрабатывать длинные мультимодальные сессии в реальном времени.

Таким образом, данная диссертация нацелена на разработку архитектуры, объединяющей перечисленные типы контекстных сигналов, и закрывает выявленный исследовательский пробел.

Таблица 1.2 – Сводная таблица ключевых работ по направлениям

Работа	**Авторы**	**Год**	**Venue**	**Направление**
GRU4Rec	Hidasi et al.	2016	ICLR	Сессионные рек. (RNN)
NARM	Li et al.	2017	CIKM	Сессионные рек. (RNN+Attention)
STAMP	Liu et al.	2018	KDD	Сессионные рек. (MLP+Attention)
SASRec	Kang & McAuley	2018	ICDM	Последовательные рек. (Transformer)
BERT4Rec	Sun et al.	2019	CIKM	Последовательные рек. (Bidirectional)
SR-GNN	Wu et al.	2019	AAAI	Графовые сессионные рек.
GC-SAN	Xu et al.	2019	IJCAI	GNN + Self-Attention
TiSASRec	Li et al.	2020	WSDM	Временные интервалы
GCE-GNN	Wang et al.	2020	SIGIR	Глобальный контекст графа
TAGNN	Yu et al.	2020	SIGIR	Target-aware GNN
LightGCN	He et al.	2020	SIGIR	Графовая кол. фильтрация
Time2Vec	Kazemi et al.	2020	ICLR	Периодическое кодирование времени
MEANTIME	Cho et al.	2020	RecSys	Смесь временных эмбеддингов
DCN V2	Wang et al.	2021	WWW	Cross-network
S^3-Rec	Zhou et al.	2020	CIKM	Self-supervised pretraining (attr.)
Transformers4Rec	Moreira et al.	2021	RecSys	NLP→RecSys фреймворк

Таблица 1.2 (продолжение)

Работа	**Авторы**	**Год**	**Venue**	**Направление**
FMLP-Rec	Zhou et al.	2022	WWW	FFT-фильтры вместо attention
MB-STR	Yuan et al.	2022	SIGIR	Multi-behavior Transformer
HRNN	Quadrana et al.	2017	RecSys	Иерархические сессионные рек. (RNN)
HCAN	Cui et al.	2019	Neurocomputing	Иерархический трансформер (сессии)
Session Tokens	Seol et al.	2022	SIGIR	Сессионные разделители
CARCA	Rashed et al.	2022	RecSys	Перекрёстное внимание + атрибуты
DuoRec	Qiu et al.	2022	WSDM	Контрастивное обучение (session)
MOJITO	Tran et al.	2023	SIGIR	Смесь временных режимов внимания
BSARec	Shin et al.	2024	AAAI	Частотный индуктивный сдвиг
PISA	Tran et al.	2024	RecSys	Session-уровень + ACT-R память
LightFM	Kula	2015	CBRecSys WS	Признаковые эмбеддинги
HGE	Serov & Trofimov	2020	DLRS WS	Графовая иерархия товаров
TIGER	Rajput et al.	2023	NeurIPS	Генеративный Semantic ID
Semantic ID Prefix	Zheng et al.	2025	RecSys	Prefix-ngram эмбеддинги

Таблица 1.2 (продолжение)

Работа	**Авторы**	**Год**	**Venue**	**Направление**
Query-Aware SR	He et al.	2022	CIKM	Поисковые запросы в рек.
HG-GNN	Pang et al.	2022	WSDM	Гетерогенный граф
TorchRec	Ivchenko et al.	2022	RecSys	Промышленная инфраструктура
BPR	Rendle et al.	2009	UAI	Парное ранжирование (pairwise)
SRNS	Ding et al.	2020	NeurIPS	Надёжный hard negative sampling
SimANS	Zhou et al.	2022	EMNLP	Полутрудные негативы (retrieval)
gSASRec	Petrov & Macdonald	2023	RecSys	Калибровка BCE (gBCE)
HNS Theory	Zhang et al.	2023	WWW	Теория hard negative sampling
LinRec	Liu et al.	2023	SIGIR	Линейное внимание
Embedding Collapse	Guo et al.	2024	ICML	Dimensional collapse
HSTU	Zhai et al.	2024	ICML	Генеративные рек. трансдьюсеры
UDITSR	—	2024	KDD	Unified Search+Rec
Mamba4Rec	Liu et al.	2024	KDD WS	SSM для рек.
TO-RoPE	Wei et al.	2025	arXiv	RoPE для рек.
SynerGen	Amazon	2025	arXiv	Генеративный unified S+R

2. Описание предлагаемого метода

2.1. Постановка задачи

Пусть задана система с множеством пользователей $\mathcal{U}$ и каталогом товаров $\mathcal{I}$. Каждый пользователь u порождает упорядоченную по времени сессию взаимодействий

$$\mathcal{S}_u = \big[(i_1, t_1),\ (i_2, t_2),\ \ldots,\ (i_n, t_n)\big], \tag{2.1}$$

где $i_k \in \mathcal{I}$ — идентификатор товара, t_k — метка времени k-го взаимодействия.

Цель. По истории сессии $\mathcal{S}_u$ предсказать следующий товар, с которым пользователь провзаимодействует:

$$\hat{i}_{n+1} = \arg\max_{i \in \mathcal{I}} P(i_{n+1} = i \mid \mathcal{S}_u). \tag{2.2}$$

Контекст применения. Задача рассматривается в условиях маркетплейса с нерегулярными временными интервалами между событиями, большим каталогом ($|\mathcal{I}| \sim 10^6$ позиций) и разреженными имплицитными сигналами обратной связи (клики, просмотры, покупки). Среди особенностей данного сеттинга выделяются:

- иерархическая структура каталога (K уровней категорий) и проблема длинного хвоста: значительная доля товаров имеет единицы взаимодействий;
- неравномерность временных разрывов $\Delta t_k = t_{k+1} - t_k$, несущих информацию об интенсивности пользовательской активности;
- иерархическая суточно-сезонная цикличность (час дня, день месяца, месяц года);
- присутствие ложных отрицательных примеров (false negatives) при отборе негативных образцов для обучения.

2.2. Предлагаемый подход

Предлагаемый метод основан на архитектуре трансформера для последовательных рекомендаций и включает три оригинальных компонента: **иерар-**

хические композитные представления товаров (раздел 2.2.2), **иерархический временные эмбеддинги** (раздел 2.2.3) и **асимметричную Коши-взвешенную функцию потерь** (раздел 2.2.4).

2.2.1. Общая архитектура

На вход модели подаётся последовательность пар $\{(i_k, t_k)\}_{k=1}^{n}$. Для каждой позиции формируется объединённое представление

$$\mathbf{h}_k = \mathbf{e}^{\text{item}}(i_k) + \mathbf{e}^{\text{time}}(t_k), \tag{2.3}$$

где $\mathbf{e}^{\text{item}}(i_k) \in \mathbb{R}^D$ — композитный эмбеддинг товара (раздел 2.2.2), $\mathbf{e}^{\text{time}}(t_k) \in \mathbb{R}^D$ — временной эмбеддинг (раздел 2.2.3). Последовательность $\{\mathbf{h}_k\}$ обрабатывается стопкой слоёв само-внимания (self-attention), после чего выходной вектор последней позиции проецируется в пространство товаров для ранжирования.

2.2.2. Иерархические композитные представления товаров

Мотивация

Стандартная таблица представлений присваивает каждому товару i независимый вектор $\mathbf{e}_i \in \mathbb{R}^D$, обновляемый только по тем мини-батчам, в которые попал данный товар. В каталоге маркетплейса значительная доля товаров — нишевые позиции с единицами покупок, для которых количество градиентных обновлений недостаточно, чтобы выучить информативное представление. При этом каталоги обладают естественной иерархией: два учебника по теории вероятностей из одной подкатегории семантически близки, однако стандартная таблица никак не кодирует эту связь — каждый товар обучается с нуля (подробный обзор подходов — в разделе 1.4.4).

Формулировка

Пусть каталог организован как K-уровневая иерархия. Для каждого товара i определена цепочка вложенных категорий $c^{(1)}(i) \supset c^{(2)}(i) \supset \ldots \supset c^{(K-1)}(i) \supset \{i\}$, где $c^{(1)}$ — корневая категория, $c^{(K-1)}$ — наиболее детальная подкатегория. Предлагается заменить единую таблицу представлений конка-

тенацией нескольких таблиц поиска, соответствующих уровням иерархии:

$$\mathbf{e}^{\text{item}}(i) = \Big[\, \mathbf{e}^{(1)}\big(c^{(1)}(i)\big) \,\big\|\, \mathbf{e}^{(2)}\big(c^{(2)}(i)\big) \,\big\|\, \ldots \,\big\|\, \mathbf{e}^{(K)}(i) \,\Big], \tag{2.4}$$

где $[\cdot\|\cdot]$ — конкатенация, $\mathbf{e}^{(k)}$ — обучаемая таблица k-го уровня размерности d_k, $\mathbf{e}^{(K)}$ — таблица уровня товаров. Общая размерность $\sum_{k=1}^{K} d_k = D$ совпадает с размерностью модели. Отображение $i \to c^{(K-1)}(i) \to \ldots \to c^{(1)}(i)$ фиксировано и хранится как буфер.

В частном случае трёхуровневой иерархии (категория — подкатегория — товар):

$$\mathbf{e}^{\text{item}}(i) = \Big[\, \mathbf{e}^{(1)}\big(c^{(1)}(i)\big) \,\big\|\, \mathbf{e}^{(2)}\big(c^{(2)}(i)\big) \,\big\|\, \mathbf{e}^{(3)}(i) \,\Big]. \tag{2.5}$$

Ключевые свойства

Перенос знаний для редких товаров. Представление категории k-го уровня $\mathbf{e}^{(k)}$ получает градиентные обновления от *всех* товаров, входящих в неё. Если подкатегория содержит n товаров с суммарно M взаимодействий, то $\mathbf{e}^{(k)}$ обновляется M раз — даже если конкретный редкий товар имеет единицы покупок. Итоговое представление такого товара сочетает надёжные верхние уровни («грубое, но информативное») и зашумлённый нижний («точное, но ненадёжное»).

Контролируемый информационный bottleneck. Конкатенация, в отличие от суммирования, позволяет явно задать баланс между общей и специфичной информацией через распределение размерностей $\{d_k\}_{k=1}^{K}$. При $D = 128$ и трёхуровневой иерархии конфигурация $d_1 = 16$, $d_2 = 16$, $d_3 = 96$ оставляет основную выразительность уровню товара, тогда как $d_1 = 16$, $d_2 = 48$, $d_3 = 64$ усиливает роль подкатегории — товары одной подкатегории a priori ближе в пространстве представлений.

Неявная регуляризация и экономия памяти. Разделение параметров между товарами одной подкатегории снижает число свободных параметров на товар с D до d_K, что действует как регуляризация для товаров средней популярности. Число параметров стандартной таблицы составляет $N \times D$, компо-

зитной — $\sum_{k=1}^{K} N_k \times d_k$, где N_k — число категорий k-го уровня. Поскольку $N_k \ll N$ для верхних уровней, при $d_K = 0{,}75D$ экономия составляет около 25% параметров основной таблицы.

Совместимость с архитектурой. Результат конкатенации — вектор размерности D, идентичный по формату стандартному представлению. Подстановка в SASRec, BERT4Rec или аналогичную модель выполняется заменой единственного модуля — слоя представлений товаров.

Основной компромисс

При фиксированной размерности D перераспределение части измерений в пользу верхних уровней *уменьшает* размерность собственной части товара ($d_K < D$). Для популярных товаров с достаточным количеством данных это может снизить выразительность. Если доля размерности, отведённая на подкатегорию, слишком велика, товары одной подкатегории становятся неразличимы. Оптимальное распределение $\{d_k\}$ зависит от датасета и подбирается экспериментально (глава 4).

2.2.3. Иерархический временные эмбеддинги

Мотивация

Стандартные позиционные кодирования не учитывают реальные метки времени. Существующие подходы (Time2Vec [35]) используют глобальные синусоидальные базисы, которые не передают локальные временные паттерны и иерархическую структуру календаря. Предлагаемый модуль устраняет эти ограничения за счёт двух идей: *иерархической декомпозиции* временной метки и *смешанного базиса* из синусоидальных и радиальных (RBF) функций.

Календарная декомпозиция

Временная метка t разбивается на иерархические остатки:

$$\tilde{t}^{(p)} = \frac{r^{(p)}(t)}{D^{(p)}} \in [0, 1), \tag{2.6}$$

где $r^{(p)}(t)$ — остаток уровня p (таблица 2.1), $D^{(p)}$ — нормировочный делитель. Каждый уровень независимо кодирует свою циклическую структуру.

Таблица 2.1 – Иерархические уровни декомпозиции временной метки

Уровень	Остаток $r^{(p)}(t)$	Единица	Делитель $D^{(p)}$
`hour`	$t - \text{start_of_hour}(t)$	минуты	60
`day`	$t - \text{start_of_day}(t)$	часы	24
`month`	$\text{start_of_day}(t) - \text{start_of_month}(t)$	дни	31
`year`	$\text{start_of_month}(t) - \text{start_of_year}(t)$	месяцы	12

Набор активных уровней является конфигурируемым параметром. Для задач электронной коммерции рекомендуется использовать уровни `day` и `month`.

Базисные функции

Для каждого уровня p применяется модуль *TimePeriodEmbedding*, объединяющий K_{sin} синусоидальных и K_{rbf} радиальных базисных функций (RBF).

Синусоидальный базис. k-й базис ($k = 1, \ldots, K_{\text{sin}}$) вычисляется как

$$s_k(\tilde{t}^{(p)}) = \sin\bigl(\omega_k \cdot \tilde{t}^{(p)} + \varphi_k\bigr), \qquad \omega_k = \text{softplus}(\hat{\omega}_k) > 0, \tag{2.7}$$

где $\hat{\omega}_k$ — обучаемый параметр (инициализируется гармониками Фурье: $\omega_k \leftarrow 2\pi k$), φ_k — обучаемая фаза. Синусоидальные базисы захватывают глобальные циклические паттерны данного уровня иерархии.

RBF-базис. k-й RBF-базис задаётся гауссовым колоколом:

$$r_k(\tilde{t}^{(p)}) = \exp\left(-\frac{(\tilde{t}^{(p)} - \mu_k)^2}{2\sigma_k^2}\right), \qquad \sigma_k = \text{softplus}(\hat{\sigma}_k) + \varepsilon, \tag{2.8}$$

где μ_k — обучаемый центр (инициализируется равномерной сеткой на $[0, 1]$), $\hat{\sigma}_k$ — обучаемый параметр ширины, $\varepsilon = 10^{-6}$. В отличие от синусоид, RBF реагирует на *локальные* зоны временной оси — всплески активности в конкретные часы суток, в начале/конце месяца и т. п. Инициализация ширин выбирается такой, чтобы активации соседних гауссианов перекрывались ровно наполовину:

$$\sigma_0 = \frac{\Delta c}{\sqrt{2\ln 2}}, \qquad \Delta c = \frac{1}{K_{\text{rbf}} - 1}. \tag{2.9}$$

Векторный выход одного периода. Каждая скалярная активация умножается на обучаемый d'-мерный вектор-амплитуду:

$$\mathbf{v}^{(p)} = \left[s_1 \mathbf{a}_1^s,\ \ldots,\ s_{K_{\sin}} \mathbf{a}_{K_{\sin}}^s,\ r_1 \mathbf{a}_1^r,\ \ldots,\ r_{K_{\mathrm{rbf}}} \mathbf{a}_{K_{\mathrm{rbf}}}^r \right] \in \mathbb{R}^{(K_{\sin}+K_{\mathrm{rbf}})\cdot d'}. \tag{2.10}$$

Векторы-амплитуды $\{\mathbf{a}_k^s, \mathbf{a}_k^r\}$ инициализируются совместно через QR-ортогонализаци с масштабом $1/\sqrt{K}$, $K = K_{\sin} + K_{\mathrm{rbf}}$, чтобы все K базисов стартовали в независимых подпространствах.

Финальное объединение

Выходы всех P уровней конкатенируются:

$$\mathbf{e}^{\mathrm{time}}(t) = \left[\mathbf{v}^{(1)},\ \mathbf{v}^{(2)},\ \ldots,\ \mathbf{v}^{(P)} \right] \in \mathbb{R}^d, \qquad d = K \cdot P \cdot d', \tag{2.11}$$

без дополнительного линейного слоя, что обеспечивает прозрачную интерпретацию каждой группы координат. Опциональный LayerNorm стабилизирует масштаб временного эмбеддинга относительно эмбеддинга товара.

Сравнение с альтернативными подходами

Синусоидальные базисы глобальны: одна и та же активация у синуса означает одинаковое положение в цикле независимо от окружающего контекста. RBF, напротив, локальны: они различают конкретные зоны временной оси. Совмещение обоих типов в одном модуле позволяет одновременно кодировать периодическую структуру (тренды суточного поведения, сезонность) и локальные концентрации активности. Альтернативный вариант — вейвлет Morlet $\psi_{a,b}(t) = a^{-1/2} \cos(\omega_0 (t-b)/a) \exp(-(t-b)^2/(2a^2))$ — обеспечивает схожую локально-колебательную выразительность, однако требует подбора дополнительных гиперпараметров (масштаб a, базовая частота ω_0) и менее стабилен при обучении, поэтому в базовой конфигурации используется упрощённый вариант с RBF.

2.2.4. Функция потерь с асимметричным Коши-взвешиванием негативов

Проблема стандартных подходов

При обучении sequential recommendation моделей с большим числом негативных примеров ($N \sim 10^4$) применяется sampled negative BCE. Стандартное (равномерное) взвешивание приводит к доминированию лёгких негативов: их тысячи, и суммарный градиент от них заглушает сигнал от информативных примеров. Противоположная крайность — softmax-weighted BCE, где веса монотонно растут с релевантностью негатива, — систематически усиливает градиент от *ложных отрицательных* примеров (false negatives), то есть товаров, которые пользователь купил бы, но ещё не купил. В условиях имплицитной обратной связи это ухудшает качество рекомендаций.

Предлагаемая функция потерь

Предлагается немонотонная весовая схема, сосредоточивающая gradient magnitude на *полутрудных* (semi-hard) негативах — достаточно информативных, но не являющихся false negatives. Функция потерь имеет вид:

$$\mathcal{L} = -\log \sigma(s^+) + \lambda \sum_{j=1}^{N} \alpha_j \cdot \left(-\log(1 - \sigma(s_j^-))\right), \tag{2.12}$$

где s^+ — logit позитивного примера, s_j^- — logit j-го негатива, λ — гиперпараметр баланса. Нормированные веса вычисляются с операцией `detach`:

$$\alpha_j = \frac{f(s_j^-)}{\sum_{k=1}^{N} f(s_k^-)}, \tag{2.13}$$

то есть перераспределяют величину градиента между негативами, не влияя на направление.

Асимметричный Коши-колокол

Весовая функция f определяется как обобщённый Коши-колокол с асимметричной шириной:

$$f(x) = \left(1 + \left(\frac{x-\mu}{a(x)}\right)^2\right)^{-p}, \tag{2.14}$$

$$a(x) = a_L + (a_R - a_L) \cdot \sigma\big(\beta(x-\mu)\big), \tag{2.15}$$

где $\sigma(\cdot)$ — логистическая функция.

Параметры и их смысл. Таблица 2.2 описывает параметры функции.

Таблица 2.2 – Параметры асимметричной Коши-весовой функции

Параметр	Что контролирует	Типичные значени
μ	Положение пика (в шкале logits)	2–5
a_L	Ширина влево: подавление лёгких негативов	1–5
a_R	Ширина вправо: подавление hardest / false negatives	0.5–3
p	Скорость убывания хвостов	1–2
β	Крутизна перехода $a_L \to a_R$	1–5

Ключевые свойства.

- **Пик при** $x = \mu$: $f(\mu) = 1$. Негативы с logit близким к μ получают максимальный вес.
- **Раздельное подавление хвостов**: параметры a_L и a_R независимо регулируют ширину левого (лёгкие негативы) и правого (hardest / false negatives) хвоста.
- **Гладкость**: функция $f \in C^\infty$, сигмоидный переход шириной β^{-1} обеспечивает плавную смену режимов.
- **Тяжесть хвостов**: при $p = 1$ хвосты убывают как $O(x^{-2})$, при $p > 1$ — быстрее.
- **Нормализация без softmax**: $\alpha = f / \sum f$ передаёт форму весовой функции напрямую, без экспоненциального искажения как в softmax.

Сравнение с существующими подходами

gBCE (Petrov & Macdonald, 2023) применяет β-преобразование позитивного примера, но равномерно взвешивает негативы. **Softmax-weighted BCE** монотонно усиливает вес наиболее релевантных негативов и систематически завышает gradient от false negatives. **Focal loss** перевзвешивает по уверенности модели, не различая hard от false-negative. Предлагаемый Коши BCE является единственным подходом, который явно моделирует «зону полезных негативов» и независимо подавляет оба хвоста.

Эффективная реализация

При $N = 16\text{K}$ негативов полный тензор весов $[B, S, N]$ занимает до 4 ГБ памяти. Для экономии памяти используется чанковая схема (chunk size $C = 4096$): первый проход аккумулирует $\sum_k f(s_k^-)$ по чанкам; второй проход вычисляет взвешенный BCE $(f(\text{chunk})/\sum f)\cdot\text{BCE}(\text{chunk})$ и суммирует. Пиковый расход дополнительной памяти составляет $2 \times [B, S, C]$ вместо $2 \times [B, S, N]$.

2.3. Выводы по главе

В данной главе описаны три ключевых компонента предлагаемого метода. Иерархические композитные представления товаров заменяют единую таблицу эмбеддингов конкатенацией таблиц по уровням каталожной иерархии, обеспечивая перенос знаний для редких товаров и контролируемый баланс между общей и специфичной информацией. Иерархический временной эмбеддинг кодирует временную метку через декомпозицию на суточные и месячные остатки и смешанный базис из обучаемых синусоидальных и RBF функций, позволяя одновременно захватывать циклические паттерны и локальные зоны активности. Асимметричная Коши-взвешенная функция потерь концентрирует обучающий сигнал на полутрудных негативных примерах за счёт немонотонной весовой функции с раздельным управлением шириной обоих хвостов, снижая влияние ложных отрицательных примеров. Совместное применение этих компонентов направлено на улучшение качества рекомендаций в условиях маркетплейса с иерархическим каталогом, нерегулярными временными разрывами и имплицитной обратной связью.

3. Результаты экспериментов

3.1. Описание эксперимента

Текст раздела . . .

3.2. Анализ результатов

Текст раздела . . .

3.3. Выводы по главе

В данной главе были представлены . . .

4. Обсуждение и сравнительный анализ

4.1. Сравнение с существующими решениями

Текст раздела . . .

4.2. Ограничения предложенного подхода

Текст раздела . . .

4.3. Направления дальнейших исследований

Текст раздела . . .

4.4. Выводы по главе

В данной главе было проведено . . .

Заключение

В рамках данной работы были получены следующие результаты:

1. Результат 1 . . .
2. Результат 2 . . .
3. Результат 3 . . .

Таким образом, поставленная цель достигнута, все задачи выполнены.

Список литературы

1. A Hierarchical Contextual Attention-Based Network for Sequential Recommendation / Q. Cui [и др.] // Neurocomputing. Т. 369. — 2019. — С. 64—73.
2. A Survey on Multi-Behavior Sequential Recommendation: Modeling, Methods, and Applications / J. Kim, Y. Lee, J. Park [и др.] // ACM Computing Surveys. — 2026.
3. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations / J. Zhai [и др.] // Proceedings of the 41st International Conference on Machine Learning (ICML). — Vienna, Austria : PMLR, 2024.
4. An Attentive Inductive Bias for Sequential Recommendation beyond the Self-Attention / Y. Shin [и др.] // Proceedings of the 38th AAAI Conference on Artificial Intelligence. Т. 38. — AAAI Press, 2024. — С. 8984—8992.
5. Attention Mixtures for Time-Aware Sequential Recommendation / V.-A. Tran [и др.] // Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Taipei, Taiwan : ACM, 2023.
6. BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer / F. Sun [и др.] // Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM). — Beijing, China : ACM, 2019. — С. 1441—1450.
7. BPR: Bayesian Personalized Ranking from Implicit Feedback / S. Rendle [и др.] // Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI). — Montreal, Canada : AUAI Press, 2009. — С. 452—461.
8. CauseRec: Counterfactual User Sequence Synthesis for Sequential Recommendation / S. Zhang [и др.] // Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Virtual Event, Canada : ACM, 2021. — С. 367—377.

9. Compositional Embeddings Using Complementary Partitions for Memory-Efficient Recommendation Systems / H.-J. M. Shi [и др.] // Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — Virtual Event : ACM, 2020. — С. 165—175.

10. Contrastive Learning for Representation Degeneration Problem in Sequential Recommendation / R. Qiu [и др.] // Proceedings of the 15th ACM International Conference on Web Search and Data Mining (WSDM). — Virtual Event : ACM, 2022. — С. 813—823.

11. Contrastive Learning for Sequential Recommendation / X. Xie [и др.] // Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Madrid, Spain : ACM, 2022. — С. 601—611.

12. CORE: Simple and Effective Session-based Recommendation within Consistent Representation Operating Environments / Y. Hou [и др.] // Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Madrid, Spain : ACM, 2022. — С. 1796—1801.

13. DCN V2: Improved Deep & Cross Network and Practical Lessons for Web-scale Learning to Rank Systems / R. Wang [и др.] // Proceedings of the ACM Web Conference (WWW). — Ljubljana, Slovenia : ACM, 2021. — С. 1785—1797.

14. DE-RRD: A Knowledge Distillation Framework for Recommender System / S. Kang [и др.] // Proceedings of the 29th ACM International Conference on Information & Knowledge Management (CIKM). — Virtual Event, Ireland : ACM, 2020. — С. 605—614.

15. Deep & Cross Network for Ad Click Predictions / R. Wang [и др.] // Proceedings of the ADKDD'17. — Halifax, NS, Canada : ACM, 2017. — 12:1—12:7.

16. Deep Interest Evolution Network for Click-Through Rate Prediction / G. Zhou [и др.] // Proceedings of the 33rd AAAI Conference on Artificial Intelligence. — Honolulu, Hawaii, USA : AAAI Press, 2019. — С. 5941—5948.

17. Deep Interest Network for Click-Through Rate Prediction / G. Zhou [и др.] // Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — London, UK : ACM, 2018. — С. 1059—1068.

18. Deep Learning Recommendation Model for Personalization and Recommendation Systems / M. Naumov [и др.] // arXiv preprint arXiv:1906.00091. — 2019.

19. *DeepSeek-AI*. DeepSeek-V3 Technical Report // arXiv preprint arXiv:2412.19437. — 2024.

20. Enhancing Embedding Representation Stability with Semantic ID / Z. Zhu, Y. Liu [и др.] // arXiv preprint arXiv:2504.02137. — 2025.

21. Federated Recommendation with Additive Personalization / T.-A. Nguyen, D.-V. Trung [и др.] // Proceedings of the ACM Web Conference (WWW). — Singapore : ACM, 2024.

22. Filter-enhanced MLP is All You Need for Sequential Recommendation / K. Zhou [и др.] // Proceedings of the ACM Web Conference (WWW). — Virtual Event : ACM, 2022. — С. 2388—2399.

23. Frequency Enhanced Hybrid Attention Network for Sequential Recommendation / X. Du, H. Yuan, P. Zhao [и др.] // Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Taipei, Taiwan : ACM, 2023. — С. 78—88.

24. From Contrastive to Non-Contrastive: Solving the Dimensional Collapse Problem in Self-Supervised Graph Collaborative Recommendation / M. Chen, L. Pan, Z. Liu [и др.] // Proceedings of the 17th ACM International Conference on Web Search and Data Mining (WSDM). — Merida, Mexico : ACM, 2024.

25. Global Context Enhanced Graph Neural Networks for Session-based Recommendatio Z. Wang [и др.] // Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. — Virtual Event, China : ACM, 2020. — С. 169—178.

26. Graph Contextualized Self-Attention Network for Session-based Recommendation / C. Xu [и др.] // Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI). — Macao, China : AAAI Press, 2019. — С. 3940—3946.

27. *Harper F. M.*, *Konstan J. A.* The MovieLens Datasets: History and Context // ACM Transactions on Interactive Intelligent Systems. — 2015. — Т. 5, № 4. — 19:1—19:19.

28. Heterogeneous Global Graph Neural Networks for Personalized Session-based Recommendation / Y. Pang [и др.] // Proceedings of the 15th ACM International Conference on Web Search and Data Mining (WSDM). — Virtual Event : ACM, 2022. — С. 775—783.

29. Heterogeneous Graph Attention Network / X. Wang [и др.] // The World Wide Web Conference (WWW). — San Francisco, CA, USA : ACM, 2019. — С. 2022—2032.

30. *Hidasi B.*, *Karatzoglou A.* Recurrent Neural Networks with Top-k Gains for Session-based Recommendations // Proceedings of the 27th ACM International Conference on Information and Knowledge Management (CIKM). — Turin, Italy : ACM, 2018. — С. 843—852.

31. Image-based Recommendations on Styles and Substitutes / J. McAuley [и др.] // Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Santiago, Chile : ACM, 2015. — С. 43—52.

32. Improving Implicit Recommender Systems with View Data / J. Ding [и др.] // Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI). — Stockholm, Sweden : AAAI Press, 2018. — С. 3343—3349.

33. Intent Contrastive Learning for Sequential Recommendation / Y. Chen [и др.] // Proceedings of the ACM Web Conference (WWW). — Virtual Event, Lyon, France : ACM, 2022. — С. 2172—2182.

34. *Kang W.-C.*, *McAuley J.* Self-Attentive Sequential Recommendation // Proceedings of the IEEE International Conference on Data Mining (ICDM). — Singapore : IEEE, 2018. — С. 197—206.

35. *Kazemi S. M.*, *Poole D.* Time2Vec: Learning a Vector Representation of Time // Proceedings of the 8th International Conference on Learning Representations (ICLR). — Addis Ababa, Ethiopia, 2020.

36. KGAT: Knowledge Graph Attention Network for Recommendation / X. Wang [и др.] // Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — Anchorage, AK, USA : ACM, 2019. — С. 950—958.

37. *Koren Y.* Collaborative Filtering with Temporal Dynamics // Communications of the ACM. — 2010. — Т. 53, № 4. — С. 89—97.

38. *Krichene W.*, *Rendle S.* On Sampled Metrics for Item Recommendation // Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — Virtual Event : ACM, 2020. — С. 1748—1757.

39. *Kula M.* Metadata Embeddings for User and Item Cold-start Recommendations // Proceedings of the 2nd Workshop on New Trends on Content-Based Recommender Systems (CBRecSys). — 2015. — С. 14—21.

40. Learning Intents behind Interactions with Knowledge Graph for Recommendation / X. Wang [и др.] // Proceedings of the ACM Web Conference (WWW). — Ljubljana, Slovenia : ACM, 2021. — С. 878—887.

41. Learning Multi-granular Quantized Embeddings for Large-Vocab Categorical Features in Recommender Systems / W.-C. Kang [и др.] // Companion Proceedings of the Web Conference 2020 (WWW). — Taipei, Taiwan : ACM, 2020. — С. 562—566.

42. *Li J.*, *Wang Y.*, *McAuley J.* Time Interval Aware Self-Attention for Sequential Recommendation // Proceedings of the 13th ACM International Conference on Web Search and Data Mining (WSDM). — Houston, TX, USA : ACM, 2020. — С. 322—330.

43. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendat X. He [и др.] // Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. — Virtual Event, China : ACM, 2020. — С. 639—648.

44. LinRec: Linear Attention Mechanism for Long-term Sequential Recommender Systems / S. Liu [и др.] // Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Taipei, Taiwan : ACM, 2023. — С. 1595—1605.

45. LoRA: Low-Rank Adaptation of Large Language Models / E. J. Hu [и др.] // Proceedings of the 10th International Conference on Learning Representations (ICLR). — Virtual Event, 2022.

46. Mamba4Rec: Towards Efficient Sequential Recommendation with Selective State Space Models / C. Liu [и др.] // Proceedings of the KDD Workshop on Relevance in the Age of Generative AI (RelKD@KDD). — Barcelona, Spain, 2024.

47. Model Size Reduction Using Frequency Based Double Hashing for Embeddings in Recommendation Systems / W. Zhang, J. Zheng, S. Gong [и др.] // Proceedings of the 14th ACM Conference on Recommender Systems (RecSys). — Virtual Event, Brazil : ACM, 2020. — С. 521—526.

48. Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts / J. Ma [и др.] // Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — London, UK : ACM, 2018. — С. 1930—1939.

49. Multi-Behavior Sequential Recommendation with Temporal Graph Transformer / W. Wang, F. Feng, X. He [и др.] // Proceedings of the 18th ACM Conference on Recommender Systems (RecSys). — Bari, Italy : ACM, 2024.

50. Neural Attentive Session-based Recommendation / J. Li [и др.] // Proceedings of the 26th ACM International Conference on Information and Knowledge Management (CIKM). — Singapore : ACM, 2017. — С. 1419—1428.

51. Neural Collaborative Filtering / X. He [и др.] // Proceedings of the 26th International Conference on World Wide Web (WWW). — Perth, Australia : ACM, 2017. — С. 173—182.

52. Neural Graph Collaborative Filtering / X. Wang [и др.] // Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. — Paris, France : ACM, 2019. — С. 165—174.

53. Neural Multi-Task Recommendation from Multi-Type User Feedback / C. Gao [и др.] // Proceedings of the 35th IEEE International Conference on Data Engineering (ICDE). — Macao, China : IEEE, 2019. — С. 1850—1861.

54. On the Embedding Collapse when Scaling up Recommendation Models / Y. Guo [и др.] // Proceedings of the 41st International Conference on Machine Learning (ICML). — Vienna, Austria : PMLR, 2024.

55. Parameter-Efficient Transfer from Sequential Behaviors for User Modeling and Recommendation / F. Yuan [и др.] // Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Madrid, Spain : ACM, 2022. — С. 1469—1478.

56. *Petrov A. V.*, *Macdonald C.* gSASRec: Reducing Overconfidence in Sequential Recommendation Trained with Negative Sampling // Proceedings of the 17th ACM Conference on Recommender Systems (RecSys). — Singapore : ACM, 2023. — С. 116—123.

57. *Prakash J.*, *McAuley J.* On Negative Sampling Strategies for Sequential Recommendation with Transformers // Proceedings of the 18th ACM Conference on Recommender Systems (RecSys). — Bari, Italy : ACM, 2024.

58. Privileged Features Distillation at Taobao Recommendations / C. Xu [и др.] // Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — Virtual Event : ACM, 2020. — С. 2590—2598.

59. Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations / H. Tang [и др.] // Proceedings of the 14th ACM Conference on Recommender Systems (RecSys). — Virtual Event, Brazil : ACM, 2020. — С. 269—278.

60. *Quadrana M.*, *Cremonesi P.*, *Jannach D.* Personalizing Session-based Recommendati with Hierarchical Recurrent Neural Networks // Proceedings of the 11th ACM Conference on Recommender Systems (RecSys). — Como, Italy : ACM, 2017. — С. 130—137.

61. Query-Aware Sequential Recommendation / Z. He [и др.] // Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM). — Atlanta, GA, USA : ACM, 2022. — С. 739—748.

62. *Rashed A.*, *Elsayed S.*, *Schmidt-Thieme L.* Context and Attribute-Aware Sequential Recommendation via Cross-Attention // Proceedings of the 16th ACM Conference on Recommender Systems (RecSys). — Seattle, WA, USA : ACM, 2022. — С. 71—80.

63. RecGRELA: Gated Recurrent Linear Attention for Sequential Recommendation / Z. Hu, Y. Zhang, W. X. Zhao [и др.] // arXiv preprint arXiv:2503.xxxxx. — 2025.

64. Recommender Systems with Generative Retrieval / S. Rajput [и др.] // Advances in Neural Information Processing Systems (NeurIPS). Т. 36. — 2023.

65. RoFormer: Enhanced Transformer with Rotary Position Embedding / J. Su [и др.] // Neurocomputing. — 2023. — Т. 568. — С. 127063.

66. S^3-Rec: Self-Supervised Learning for Sequential Recommendation with Mutual Information Maximization / K. Zhou [и др.] // Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM). — Virtual Event, Ireland : ACM, 2020. — С. 1893—1902.

67. Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction / Q. Pi [и др.] // Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM). — Virtual Event, Ireland : ACM, 2020. — С. 2685—2692.

68. Semantic ID Prefix-Ngram Embeddings for Scalable Recommendation Systems / J. Zheng [и др.] // Proceedings of the 19th ACM Conference on Recommender Systems (RecSys). — ACM, 2025.

69. *Seol J.*, *Ko S.*, *Lee J.* Exploiting Session Information in BERT-based Session-aware Sequential Recommendation // Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. — Madrid, Spain : ACM, 2022. — С. 2155—2159.

70. *Serov A.*, *Trofimov I.* Hierarchical Graph Embedding for Category-Aware Item Recommendation // Proceedings of the Workshop on Deep Learning for Recommendation Systems (DLRS). — ACM, 2020.

71. Session-based Recommendation with Graph Neural Networks / S. Wu [и др.] // Proceedings of the 33rd AAAI Conference on Artificial Intelligence. — Honolulu, Hawaii, USA : AAAI Press, 2019. — С. 346—353.

72. Session-based Recommendations with Recurrent Neural Networks / B. Hidasi [и др.] // Proceedings of the 4th International Conference on Learning Representations (ICLR). — San Juan, Puerto Rico, 2016.

73. SimANS: Simple Ambiguous Negatives Sampling for Dense Text Retrieval / K. Zhou [и др.] // Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing: Industry Track. — ACL, 2022. — С. 598—607.

74. Simplify and Robustify Negative Sampling for Implicit Collaborative Filtering / J. Ding [и др.] // Advances in Neural Information Processing Systems (NeurIPS). Т. 33. — 2020. — С. 1094—1105.

75. STAMP: Short-Term Attention/Memory Priority Model for Session-based Recommendation / Q. Liu [и др.] // Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — London, UK : ACM, 2018. — С. 1831—1839.

76. SynerGen: Synergistic Generative Pre-Training for Joint Search and Recommendation G. Wang, L. Liao [и др.] // arXiv preprint arXiv:2506.xxxxx. — 2025.

77. *Tagliabue J.*, *Yu B.*, *Beaulieu-Jones B.* Shopping in the Multiverse: A Counterfactual Approach to In-Session Attribution // Proceedings of the SIGIR 2021 eCom Data Challenge. — 2021.

78. TAGNN: Target Attentive Graph Neural Networks for Session-based Recommendatio F. Yu [и др.] // Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. — Virtual Event, China : ACM, 2020. — С. 1921—1924.

79. *Tang J.*, *Wang K.* Ranking Distillation: Learning Compact Ranking Models with High Performance for Recommender System // Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — London, UK : ACM, 2018. — С. 2289—2298.

80. TO-RoPE: Time-Offset Rotary Position Embedding for Sequential Recommendation / Y. Wei, P. Xu, H. Zhang [и др.] // arXiv preprint arXiv:2502.xxxxx. — 2025.

81. Topology Distillation for Recommender System / S. Kang [и др.] // Proceedings of the 27th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — Virtual Event, Singapore : ACM, 2021. — С. 829—839.

82. TorchRec: A PyTorch Domain Library for Recommendation Systems / D. Ivchenko [и др.] // Proceedings of the 16th ACM Conference on Recommender Systems (RecSys). — Seattle, WA, USA : ACM, 2022. — С. 482—484.

83. Towards Deeper, Lighter and Interpretable Cross Network for Recommendation / S. Wang [и др.] // Proceedings of the 32nd ACM International Conference on Information and Knowledge Management (CIKM). — Birmingham, UK : ACM, 2023. — С. 4208—4217.

84. Towards Theoretically Inspired Neural Initialization for Deep Recommender Systems / J. Shi [и др.] // Proceedings of the ACM Web Conference (WWW). — Austin, TX, USA : ACM, 2023. — С. 1360—1369.

85. Transformers Meet ACT-R: Repeat-Aware and Sequential Listening Session Recommendation / V.-A. Tran [и др.] // Proceedings of the 18th ACM Conference on Recommender Systems (RecSys). — Bari, Italy : ACM, 2024.

86. Transformers4Rec: Bridging the Gap between NLP and Sequential / Session-Based Recommendation / G. d. S. P. Moreira [и др.] // Proceedings of the 15th ACM Conference on Recommender Systems (RecSys). — Amsterdam, Netherlands : ACM, 2021. — С. 143—153.

87. Unified Dual-Intent Translation for Joint Modeling of Search and Recommendation / M. Zhang, J. Zhang [и др.] // Proceedings of the 30th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — Barcelona, Spain : ACM, 2024.

88. Wide & Deep Learning for Recommender Systems / H.-T. Cheng [и др.] // Proceedings of the 1st Workshop on Deep Learning for Recommender Systems (DLRS@RecSys). — Boston, MA, USA : ACM, 2016. — С. 7—10.

89. *Zamani H.*, *Croft W. B.* Learning a Joint Search and Recommendation Model from User-Item Interactions // Proceedings of the 13th ACM International Conference on Web Search and Data Mining (WSDM). — Houston, TX, USA : ACM, 2020. — С. 717—725.

A. Дополнительные материалы